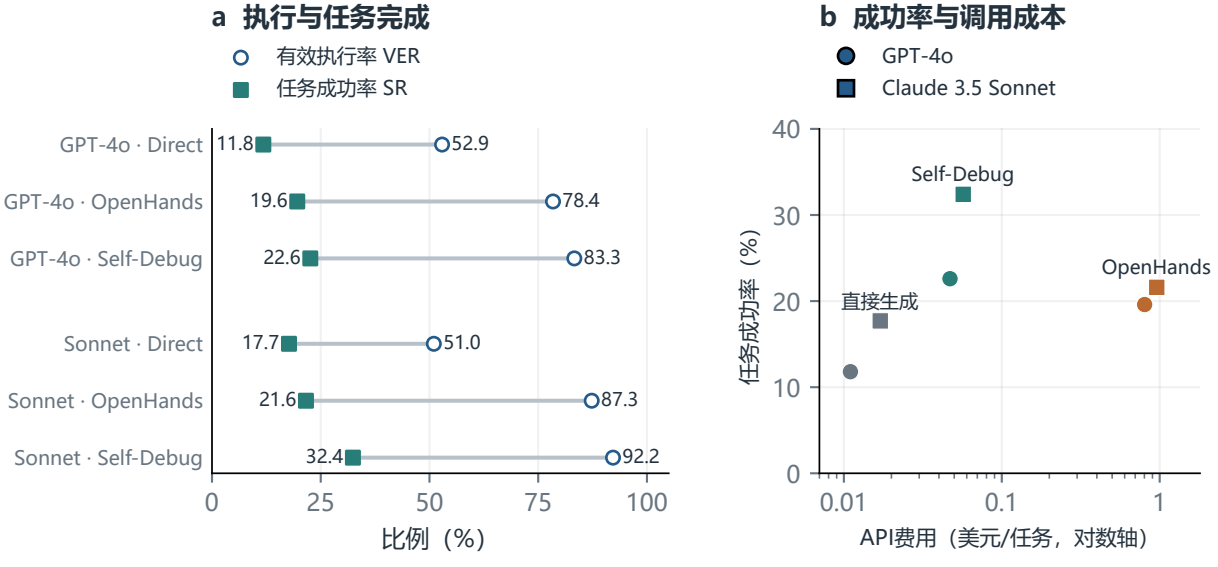
a 执行与任务完成
有效执行率 VER
任务成功率 SR
GPT-4o · Direct
GPT-4o · OpenHands
GPT-4o · Self-Debug
Sonnet · Direct
Sonnet · OpenHands
Sonnet · Self-Debug
11.8
52.9
19.6
78.4
22.6
83.3
17.7
51.0
21.6
87.3
32.4
92.2
0
25
50
75
100
比例（%）
b 成功率与调用成本
GPT-4o
Claude 3.5 Sonnet
Self-Debug
OpenHands
直接生成
任务成功率（%）
40
30
20
10
0
0.01
0.1
1
API费用（美元/任务，对数轴）