

ZJU-UIUC INSTITUTE

Zhejiang University-University of Illinois Urbana-Champaign Institute

浙江大学伊利诺伊大学厄巴纳香槟校区联合学院

工程技术前沿

2026 年秋季　期中文献综述

面向科研任务的多智能体系统

知识增强、记忆机制与可信性评估

中文文献综述初稿

作者姓名待填写

学号待填写

2026 年 11 月 9 日

摘要

大语言模型正在从提供文本答案的工具，转向能够检索文献、调用程序并参与实验的科研助手。然而，多个智能体完成一套流程，并不意味着所得结论已经可靠。本文围绕知识增强、记忆管理与协作核验三个方面，对十篇代表性原始文献进行比较，讨论 RAG 与 GraphRAG 的证据组织、代理记忆的状态维护，以及工具反馈和角色协作的关系。本文认为，外部知识、任务经历与科研结论应分别管理：图结构有助于跨文档组织，记忆机制有助于维持长期任务，但二者都可能固化已有错误；多角色一致也不能代替独立证据。在此基础上，本文提出以证据记录、版本更新和分阶段人工审查组织科研辅助流程，并从引用支持度、复现完整性及失败恢复能力等维度讨论评价方法。相关流程为文献基础上的分析与设计建议，不代表本文完成了新的系统实验。

关键词：多智能体；科研辅助；检索增强生成；长期记忆；可信性

1 问题引入：从生成答案到参与科研

一项研究通常不是一次问答，而是一串相互依赖的判断：哪些文献与问题相关，已有结论在什么条件下成立，新的实验是否公平，结果又能支持多大范围的推论。语言模型可以快速生成检索词、代码和写作提纲，却也可能遗漏限定条件，或把语言流畅的推测写成确定结论。当这些输出成为下一阶段的输入时，早期错误便可能在完整而连贯的研究叙述中被掩盖。

课堂关于知识增强、记忆与自动科研的讨论，可以共同归结为一个问题：系统怎样在较长任务中保持对证据和自身状态的正确认识？对此，单纯扩大上下文、增加角色或让模型多次反思，都只解决了部分困难。本文将讨论限定为基于大语言模型的科研辅助系统，不展开群体机器人和全部多智能体强化学习方法。这里的“智能体”指能够结合当前目标与观察，选择工具或后续动作的任务主体；多智能体则进一步引入分工、通信和协调，并不要求每个主体使用不同的基础模型。

本文选取检索增强、上下文利用、代理记忆、协作框架与失败分析等方向的十篇论文。文献最初发表于 2020 至 2025 年，检索和版本核对截至 2026 年 11 月 9 日，属于面向课程问题的代表性综述，而非穷尽所有新工作的系统综述。比较重点是方法分别解决了什么问题、证据在哪个环节进入，以及结论的适用边界。本文不将不同数据集、基础模型和调用预算下的分数直接排列为统一榜单。

2 知识增强：信息可获得与证据可追溯

2.1 检索增强生成的基本作用

RAG 将生成模型的参数知识与可检索的外部文档结合，使回答不必完全依赖模型训练时记住的内容。Lewis 等的原始工作同时设计检索器和生成器，并比较不同的文档条件

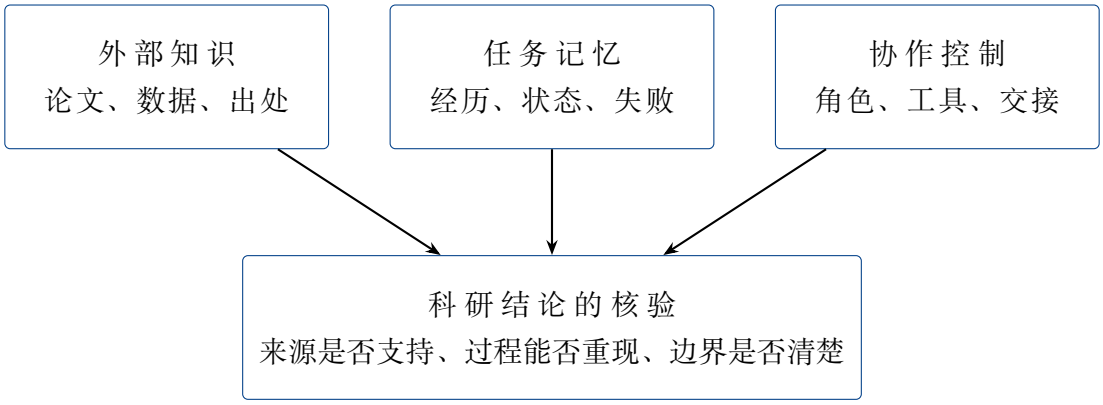


图 1: 本文归纳的三个功能层面。知识、记忆与协作分别参考文献 [1, 5, 7]，三者与核验的组织关系为本文分析，不是已验证的新架构。

化方式 [1]。在科研辅助中，这一思路的价值在于让结论能够回到具体文献，而不只是得到一句似乎正确的答案。但检索命中只是起点：段落与问题相似，未必意味着它支持当前论断；同一结论在综述、原始实验和评论文章中的证据地位也可能不同。

因此，科研系统不仅要保存检索结果，还应记录“哪条断言由哪段原文支持”。例如，一篇论文在特定数据集上获得较好结果，不应被改写成某类方法普遍优于另一类方法。这不是通过增加引文数量就能解决的问题，而需要核对实验条件、比较对象和作者限定。本文据此把证据可追溯性理解为断言、原始片段及适用条件之间的对应关系。

2.2 图结构适合什么问题

当问题从查找一个事实转向总结一个领域，相关信息可能分散在多篇文献中。GraphRAG 通过抽取实体和关系、组织图社区并生成社区摘要，支持面向整体语料的总结 [2]。它提示我们，知识增强不只是在检索数量上做加法，还可以改变信息的组织方式。不过，图结构的作用应结合查询类型判断：查找某项实验参数时，直接定位原文可能更清楚；梳理多个主题之间的联系时，结构化组织才更有讨论价值。

图索引也会引入新的误差位置。实体归并错误可能把不同研究对象当成同一对象，关系抽取可能遗漏否定或条件，摘要又会进一步压缩细节。GraphRAG 原文主要评价特定语料上的全局理解，并讨论评估与虚构率比较的局限 [2]。因此，“总结更全面”不能直接等同于“每项事实更准确”。对科研任务而言，图应当充当组织证据的入口，不能取代需要时返回原文的能力。

2.3 上下文长度不是知识利用能力

另一种直观做法是把所有材料一次放入较长输入。Lost in the Middle 通过改变相关信息的位置，发现所测模型在多文档问答和键值检索中并不能稳定利用长上下文，中部信息尤其可能被忽视 [3]。该结果不能被外推为所有后续模型都有同等程度的退化，却说明窗口容量与有效利用需要分开评价。科研系统应根据当前子任务选择证据、保留出处，并允许补充检索，而不是假设模型读到全文就已经正确处理了全文中的每项限定。

3 记忆机制：保留经历，也保留纠错的可能

3.1 知识库与任务记忆的区别

知识库主要回答外部世界中已有何种证据，任务记忆则回答本项目已经做过什么。两者都可以通过检索调用，却不应混成没有来源差异的文本池。原始实验观察、代理的临时解释和已经否定的假设，具有不同可信程度。如果它们被统一压缩成“已知事实”，系统可能在后续步骤中重复使用早期猜测。

Generative Agents 将经历记录、记忆检索、反思与规划联系起来，展示了代理如何依据过去经历维持较连贯的社会行为 [4]。它为长期任务提供了有启发性的机制，但行为看起来可信与科学事实为真是两种评价目标。把这类记忆用于科研时，不能只迁移“反思”这个名称，还要回答总结是否保留原始条件、错误反思能否被追溯，以及后来出现的反证如何进入状态更新。

3.2 分层记忆与版本管理

MemGPT 借鉴分层存储，区分当前上下文与外部存储，并通过显式调用调入信息 [5]。这使长期经历不必始终占用当前窗口，也让记忆调度成为可以设计的过程。它解决的是信息可访问与调度问题，本身并不保证写入内容真实。

本文认为，科研记忆更适合采用保留来源和版本的记录方式。一条记录至少应说明观察对象、实验条件、产生时间、当前状态以及对应文件或文献。如果新的证据推翻旧判断，应将旧判断标为已修正，而不是悄悄覆盖，因为“为什么改变方向”本身也是研究过程的重要组成部分。这一做法增加了记录负担，却有助于复查失败和区分方法无效与实现有误。相比无限积累对话，保留能够重建判断的少量关键记录可能更实用；这一取舍仍应通过具体任务检验，而不能只凭记忆条目多少评价系统。

4 多智能体协作：分工不等于独立核验

4.1 工具反馈与角色通信

ReAct 把推理与行动交替组织，使代理能够通过外部观察修正后续动作 [6]。它不是多代理框架，却解释了科研助手的重要基础：代码执行错误、检索失败或实验结果，可以提供不同于文本自我评价的反馈。工具也可能出错，因此反馈仍需结合任务含义解释；程序成功运行，不能自动证明实验设计公平或研究假设成立。

AutoGen 进一步提供可对话的代理和可编程的交互方式，将模型、工具与人的输入组合起来 [7]。其研究价值不只是给模型安排几个身份，而是把消息、执行和控制流程纳入系统设计。在科研场景中，检索者可以提供原文证据，执行者提供运行记录，检查者核对二者是否支持结论。这种分工是否有效，取决于各角色有没有获得不同的观察、是否清楚交接要求，以及谁有权要求返工。

4.2 科研流程整合与失败来源

Agent Laboratory 把文献阅读、实验和报告撰写组织为连续流程，并允许人在不同阶段提供反馈 [8]。它展示了科研辅助由单项工具走向流程整合的可能性，但完成报告只是中间产物，研究质量仍需检查问题价值、实验合理性及结果解释。该论文关于人工参与的比较也提示，自动化程度和科研质量不应被当成同一指标。

从反面看，多智能体可能把通信和交接变成新的失败来源。Cemri 等将失败归纳为规范与系统设计、代理间协作失配以及任务核验等类别 [9]。这使评价从“最后答案错了”推进到“哪一步失去约束或未被检查”。对于科研任务，角色重复执行、忽略前序证据、过早结束和错误验收都可能使流程表面完整、实际无效。因此，增加角色之前应先定义它带来何种新的能力或独立观察。

表 1: 代表性方法的功能与适用边界。依据所列论文归纳，不构成统一性能排名。

方法	主要机制与作用	科研使用中的边界
RAG[1]	从外部文档检索信息，辅助生成	检索相关不等于支持断言
GraphRAG[2]	图社区与摘要组织全局信息	抽取和摘要可能遗漏条件
Generative Agents [4]	经历检索、反思和规划	社会行为可信不等于科学事实正确
MemGPT[5]	在有限窗口与外部存储间调度	可访问性不保证记忆内容真实
ReAct[6]	交替推理、行动并接收反馈	单代理方法；工具反馈仍需解释
AutoGen[7]	可编程的多角色对话与工具交互	交接、停止与验收规则需要设计
Agent Laboratory[8]	连接文献、实验与报告流程	流程完成度不能代替科研质量

5 可信性评价：从答案评分转向证据与过程

5.1 为什么多次检查仍可能出错

同一个模型对同一段材料反复评价，未必能获得新的信息。Huang 等研究了没有外部反馈的内在自我纠错，发现所测推理任务中的纠错并不稳定，甚至可能改变原先正确的答案 [10]。这一结论有具体模型与任务边界，不意味着后续所有自我修正方法都无效，但足以提醒我们：要求模型“再认真检查一次”，不能被当成可靠验证的通用保证。

这一点也影响多角色审核的解释。如果几个代理共享同一检索片段和同一错误前提，它们可能一致接受错误结论。图2区分了仅有语言一致与具有额外证据的核验。后者也不是绝对正确，却至少增加了可以被第三方检查的观察。科研系统应说明验证者依据了什么，而不只是报告多少代理赞成。

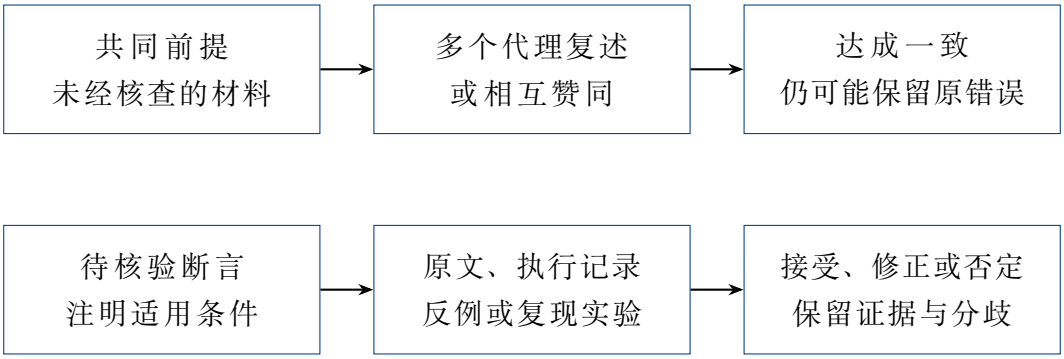


图 2: 一致意见与证据核验的区别。依据文献 [9, 10] 启发绘制；上下两条路径是本文分析示意，不是效果对比实验。

5.2 应当怎样比较系统

综合前述文献，本文建议将结果、证据与过程分开评价，见表2。引用支持度检查来源是否真正支持断言，复现完整性关注从数据到结果能否重建，失败恢复则关注系统能否识别异常并修改计划。这些维度是本文的评价建议，不是各篇论文共享的一套现成指标，也不应在没有标注和测试时直接填入主观分数。

比较多代理与单代理时，还应尽可能控制基础模型、输入材料、工具权限和总调用预算。否则更好的结果可能来自更多计算或更多人工修改，不能独立归因于角色数量。科研任务同时有自动可检验和难以自动判断的部分：数值指标可以重复计算，但一个问题是否值得研究、结论是否超出证据，往往仍需要领域判断。因此，评价应保留人的审查，同时记录人工帮助的程度，而不是将其隐藏在自动系统的成绩里。

表 2: 本文建议的科研辅助系统评价维度；没有填入虚构实验数据。

评价维度	可检查对象	容易出现的误判
结论与引用	断言、原文片段、限定条件	有引用即视为证据充分
实验可重建	数据划分、配置、日志和输出	代码能运行即视为复现成功
过程可追溯	状态更新、分工交接、版本变化	把自动摘要当作原始记录
异常与恢复	报错、冲突证据、返工与停止理由	只看最终报告而忽略失败过程
成本与参与	调用预算、工具成本、人的修改	将额外资源收益归因于多角色

6 讨论：怎样组合方法而不放大错误

6.1 以问题决定结构，而不是以框架决定问题

本文认为，多智能体系统更适合被理解为一种研究组织方式，而不是科研可靠性的直接来源。当任务可分解、子任务有不同工具、并且交付结果可检查时，分工有明确价值。若只是核查一项小事实，一个能够检索原文的代理可能已经足够；再安排多个角

色讨论，反而增加消息重复和状态不一致的机会。这种判断并不否认协作，而是要求每项新增结构解释自己的必要性。

同样，知识图谱和长期记忆没有天然的优劣排序。面向领域主题梳理，图结构可以提供组织线索；面向具体实验的重试，运行记录和失败原因更直接。比较合理的组合是将稳定的外部材料与不断变化的项目状态分别存储，通过文献或实验标识关联，而不是把一切都压缩为单一“知识”。这样做也方便发现：某项结论来自原始论文，还是来自本项目代理的一次临时解释。

6.2 一个面向文献复现任务的设计设想

以“阅读某篇机器学习论文并复现其基线”为例，图3给出一种可能流程。检索角色先输出包含出处和条件的证据记录，计划角色据此列出数据、评价协议与待确认项，执行角色保存配置、程序版本和运行结果，核验角色检查结果是否能支持报告中的断言。研究者在问题选择、关键实验设计和最终解释处保留审查权。这个例子用于说明方法如何衔接，不表示本文已经实现或验证该系统。

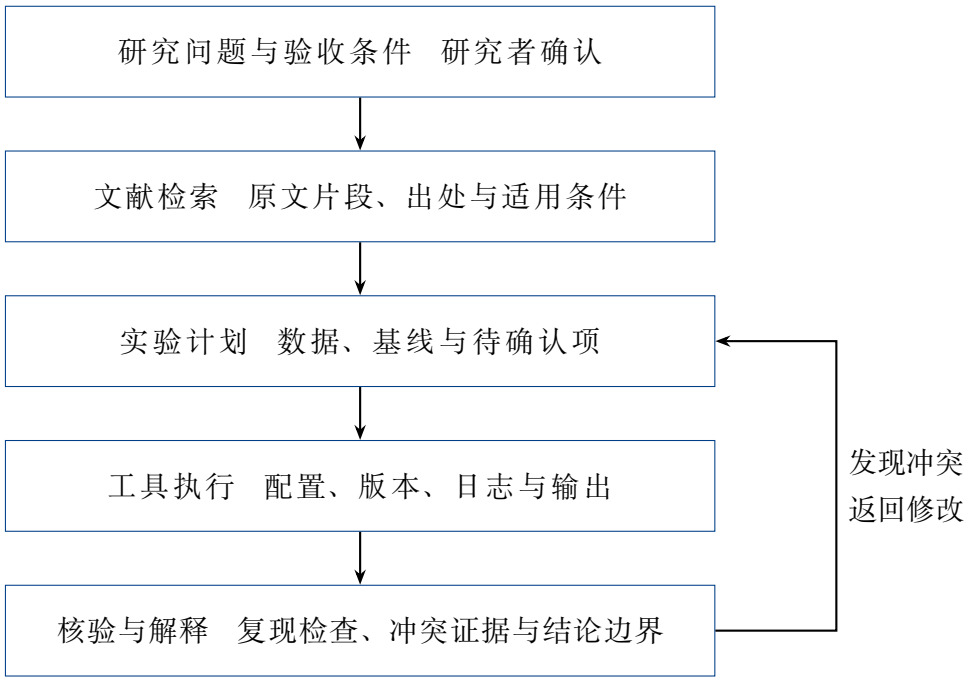


图 3: 面向论文复现的科研协作流程设想。结合文献 [1, 6, 7, 8] 讨论的机制绘制，具体交付要求与返工路径为本文建议。

假设复现结果与原论文存在差异，系统不应立即把原因概括为“方法无效”。首先需要区分数据预处理、随机性、实现差异和实验条件，再判断是否有理由质疑原结论。若核验角色只能看到执行者写下的摘要，而看不到实际配置和输出，就难以完成这一判断。因此，角色间传递的最好是可检查的交付物，摘要则保留指向交付物的索引。当证据相互冲突时，允许系统报告“不确定”比强行汇总为一个答案更符合研究工作的要求。

6.3 可信性与创新性之间的取舍

课程讨论中的可信性与创新性，并不一定随自动化程度同步提高。严格依据既有材料回答，可能更加稳妥，却未必提出有价值的新方向；允许代理自由探索，可以扩大候选假设，但也增加缺乏证据的推测。本文倾向于将两种活动分开：生成假设时可以保留多种可能，形成报告结论时则逐项要求证据。假设被记录不代表它已被接受，未验证设想也不应在记忆更新后变成既定事实。

这一取舍最终涉及人的作用。研究者不必逐字检查每条对话，但应把有限注意力放在代价高、难以逆转或最影响结论的节点上。多代理的合理目标，是减少检索、整理和重复执行的负担，使人更容易检查关键判断，而不是用一个自动生成的完整叙事遮住仍未解决的不确定性。本文讨论仍受代表性文献选择限制，未对 2026 年的所有新系统作全面评价，也没有通过统一实验确定某种组合最优；这些问题需要可复现的后续比较。

7 结论

面向科研的多智能体系统需要同时处理外部证据、长期任务状态和协作控制。RAG 与 GraphRAG 提供不同的信息组织思路，记忆机制支持跨步骤延续，工具交互与多角色协作则连接行动和反馈。这些方法能够互补，但任一环节也可能产生并传播错误。本文的主要判断是：评价科研助手应优先检查证据是否支持断言、过程能否重建，而不是仅依据回答流畅程度、记忆规模或代理数量。通过分离事实与假设、保留状态版本、检查角色交付物，并在关键节点引入领域判断，多智能体才更可能成为可检查的科研辅助工具。自动完成流程是能力展示的起点，能够说明结论依据及适用边界，才是科研应用中更值得追求的目标。

参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. 2020. arXiv:2005.11401v4. https://arxiv.org/abs/2005.11401v4.

[2] Edge D, Trinh H, Cheng N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization[EB/OL]. 2024. arXiv:2404.16130v2. https://arxiv.org/abs/2404.16130v2.

[3] Liu N F, Lin K, Hewitt J, et al. Lost in the Middle: How Language Models Use Long Contexts[EB/OL]. 2023. arXiv:2307.03172v3. https://arxiv.org/abs/2307.03172v3.

[4] Park J S, O'Brien J C, Cai C J, et al. Generative Agents: Interactive Simulacra of Human Behavior[EB/OL]. 2023. arXiv:2304.03442v2. https://arxiv.org/abs/2304.03442v2.

[5] Packer C, Wooders S, Lin K, et al. MemGPT: Towards LLMs as Operating Systems[EB/OL]. 2023. arXiv:2310.08560v2. https://arxiv.org/abs/2310.08560v2.

[6] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[EB/OL]. 2022. arXiv:2210.03629v3. https://arxiv.org/abs/2210.03629v3.

[7] Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[EB/OL]. 2023. arXiv:2308.08155v2. https://arxiv.org/abs/2308.08155v2.

[8] Schmidgall S, Su Y, Wang Z, et al. Agent Laboratory: Using LLM Agents as Research Assistants[EB/OL]. 2025. arXiv:2501.04227v2. https://arxiv.org/abs/2501.04227v2.

[9] Cemri M, Pan M Z, Yang S, et al. Why Do Multi-Agent LLM Systems Fail?[EB/OL]. 2025. arXiv:2503.13657v2. https://arxiv.org/abs/2503.13657v2.

[10] Huang J, Chen X, Mishra S, et al. Large Language Models Cannot Self-Correct Reasoning Yet[EB/OL]. 2023. arXiv:2310.01798v2. https://arxiv.org/abs/2310.01798v2.