面向科研任务的多智能体系统综述

技术脉络、关键方法与可信评价

蒋佳豪　学号：22671064
浙江大学伊利诺伊大学厄巴纳香槟校区联合学院

摘　要　大语言模型正推动科研辅助由文献问答和代码生成，向涵盖假设提出、实验执行及结果论证的连续工作流发展。多智能体系统通过任务分解、角色协作和工具调用，为复杂研究过程提供了新的组织方式，其研究重点也逐渐从单项任务性能转向长期协作能力与科学产出的有效性。本文围绕知识增强、长期记忆、协作控制和可信评价，梳理科研多智能体系统的发展脉络与主要技术路线。首先建立研究流程与支撑机制相结合的分类框架，比较片段检索、层次检索、图组织、反思记忆及多种协作拓扑；继而分析文献综合、假设生成、计算实验和实体实验中的代表性系统，讨论其自动化范围、反馈来源与验证方式。结合科学任务基准和过程审计的公开结果，进一步辨析执行成功与任务完成、候选排序与科学验证之间的差异。在此基础上，本文认为知识结构与研究状态的协同维护、探索资源与验证资源的合理分配，以及人工判断在关键研究节点的参与，是提高系统实用性的重要方向。未来研究需要在可追溯证据、长期任务评价和可复现流程的基础上，检验多智能体协作带来的实际科研增益。

关键词　科研智能体；多智能体协作；检索增强生成；长期记忆；科学发现；可信评价

A Review of Multi-Agent Systems for Scientific Research: Technical Evolution, Core Methods and Trustworthy Evaluation

Abstract　Large language models are extending research assistance from literature question answering and code generation to workflows that include hypothesis formulation, experimentation and scientific argumentation. Multi-agent systems organize these capabilities through task decomposition, role coordination and tool use. This review traces their development and synthesizes four technical dimensions: knowledge augmentation, long-term memory, collaborative control and trustworthy evaluation. It compares retrieval structures, reflective memory and communication topologies, then examines representative systems for literature synthesis, hypothesis generation, computational research and physical experimentation. Published benchmark and auditing results are used to distinguish executable programs from successful research tasks, and candidate ranking from empirical validation. The discussion identifies coordinated knowledge and state management, balanced allocation of exploration and verification resources, and human participation at critical decisions as priorities for practical research systems. Future progress requires evaluations grounded in traceable evidence, reproducible workflows and sustained research tasks.

Keywords　scientific agents; multi-agent collaboration; retrieval-augmented generation; long-term memory; scientific discovery; trustworthy evaluation

1　引言

科学研究通常由一系列相互依赖的活动构成：从已有文献中识别问题，提出能够被检验的解释，选择实验或计算方法，再依据结果修订认识。这些活动既需要广泛的信息获取，也需要领域判断与持续的过程管理。传统人工智能工具多针对其中的局部环节，例如预测分子性质、拟合实验数据或优化模型参数。近年来，大语言模型（large language model，LLM）在自然语言理解、代码生成和工具调用方面的进展，使同一系统能够跨越多个研究环节，并根据中间结果调整后续行动。科研智能体由此成为连接通用语言能力与专门研究工具的重要技术形态[1,2]。

与一次生成完整答案的模型调用相比，智能

体强调目标、行动与环境反馈之间的循环。检索增强生成（retrieval-augmented generation，RAG）为系统提供可更新的外部资料[3]，ReAct 将推理过程与工具行动交替组织[4]，AutoGen 等框架则将多个任务主体、工具和人的反馈纳入可编程的交互过程[5]。在科研场景中，这些能力可以分别用于检索文献、提出候选假设、编写实验程序、分析结果和整理报告。多智能体系统进一步通过分工与通信协调这些活动，使研究工作流具备一定的并行性、专门化程度和迭代能力。

这一发展也带来了新的评价问题。研究流程能够自动运行，并不意味着各阶段的判断都获得充分支持。检索段落可能与问题相关却不支持所引结论；代码可以正常执行，却采用了不恰当的数据划分；多个代理可以形成一致意见，却仍共享同一个错误前提。因此，科研系统的进步需要同时考察能力覆盖与研究有效性。The AI Scientist 的端到端流程、Virtual Lab 的实验设计，以及针对自动科研过程的受控审计，分别展示了自动化潜力、外部验证方式和方法学风险[6–8]。如何理解这些证据之间的关系，是综述此类系统时不能回避的问题。

1.1 相关综述与本文视角

已有综述从不同角度整理了科研智能体研究。Zheng 等以工具、分析者和科学家三个自主层次刻画 LLM 在研究中的角色变化[1]；Wei 等将能力、科研过程与学科应用联系起来，讨论生命科学、化学、材料和物理等方向[2]；郑逸宁等从工具使用的定义、发展路径与学习方法出发，总结了 LLM 与外部环境交互的关键问题[9]。这些工作分别强调自主程度、领域应用和底层能力，为理解科研系统提供了互补视角。

本文关注的问题是：知识获取、记忆维护与协作机制如何共同影响科研过程，以及现有评价在多大程度上能够反映这些机制的作用。据此，全文不以框架名称为主线，而从研究任务所需的功能出发组织材料。方法部分比较不同机制的处理对象与适用条件，系统部分分析其在科研工作流中的组合方式，评价与讨论部分则进一步考察实验依据、资源约束与人的参与。这一组织方式兼顾问题背景、方法归纳和综合判断，旨在使读者既能把握技术进展，也能理解方法选择背后的依据。

1.2 文献范围与文章结构

本文属于结构化的叙述性综述。资料核对截至 2026 年 11 月 9 日，主要通过论文题名、关键词检索和引用追踪，获取研究论文及相关综述，并回到原始报告核对机制、实验设置和主要结果。文献选择兼顾基础方法、科研系统及失败分析，重点纳入能够说明知识、记忆、协作与评价关系的工作。对同一项目的不同报告保留版本关系，例如 The AI Scientist 的早期预印本、第二版系统与 2026 年期刊稿，在讨论中按各自提供的证据引用，不将其视为相互独立的重复验证。本文未开展穷尽式数据库检索与元分析，因此不据此估计整个领域的论文分布或总体效果。

第 2 节梳理发展脉络与技术框架，第 3 节总结知识增强及记忆机制，第 4 节讨论协作组织与搜索控制；第 5 节比较科研应用中的代表系统，第 6 节整理评价方法及实证结果，第 7 节给出综合讨论与研究展望。全文以 LLM 驱动的科研系统为对象，不展开全部多智能体强化学习和群体机器人方法。蛋白质结构预测等专用模型作为可调用工具纳入讨论，其自身性能与代理协作效果分别分析。

2 发展脉络与技术框架

2.1 从工具增强到研究流程组织

科研智能体的发展并非单一路线的替代，而是知识获取、工具使用和过程组织逐步结合的结果，见图1。RAG 将非参数化检索与语言生成联系起来，使回答可以利用训练之外的资料[3]。ReAct 进一步通过行动获取环境观察，使检索和执行结果能够影响后续推理[4]。Toolformer 则从训练角度研究模型如何决定调用何种工具、传入哪些参数以及怎样利用返回值[10]。三者分别改变了信息来源、交互过程和工具调用能力，构成了科研助手进入外部环境的基础。

在此基础上，研究者开始处理长任务中的经历保留与角色协调。Reflexion 将任务反馈转化为可供后续尝试使用的文字反思[11]，Generative Agents 和 MemGPT 分别探索经历检索与分层存储[12,13]。AutoGen 与 MetaGPT 则从代理交互、标准化交付和流程约束等角度组织多个模型实例[5,14]。这些机制使研究活动不必在每次模型调用后重新开始，也使复杂任务可以被拆分为相互衔接的子任务。

面向科学研究的系统进一步把上述能力组合

到具体场景。ResearchAgent 和 SciAgents 侧重利用文献关联生成研究方向，Agent Laboratory 组织计算研究流程，AI co-scientist 强调候选假设的生成与演化，而 Virtual Lab 和 Coscientist 将规划与实体实验联系起来[7,15–19]。2026 年的 The AI Scientist 期刊研究进一步同时讨论模板驱动和开放搜索两种模式[6]。这些进展表明，研究焦点已由模型能否完成单个步骤，转向多个步骤如何组成可持续运行、可评价的研究过程。

2.2 科研工作流中的功能分层

从工作流看，科研活动可以概括为问题形成、方案与实现、观察与分析、论证与交流四个相互联系的阶段。实际研究往往在这些阶段之间往返，因而系统需要同时管理材料、状态和控制，见图2。知识获取负责提供外部论文、数据和工具说明；长期记忆保存项目经历及其解释；协作控制负责选择动作、分配任务、整合输出并决定返工或停止。三类机制分别对应信息可获得性、任务连续性与过程协调性。

这种分层有助于区分系统能力的来源。模型没有找到相关结果，可能是检索覆盖不足；已经检索到的材料被后续阶段遗忘，涉及状态管理；材料和状态均存在但任务仍然偏离目标，则需要检查计划与交接规则。如果只用最终答案分数描述系统，这些性质不同的问题就容易被归入同一类“模型能力不足”。功能分层并不要求物理上部署独立模块，而是为方法比较、系统消融和失败定位提供统一的描述方式。

2.3 单智能体与多智能体的关系

智能体通常由基础模型、可用工具、状态及动作选择规则共同构成。在给定研究目标 g 下，其行为可抽象为

$$a_t \sim \pi_\theta(a \mid g, o_{\le t}, m_t), \tag{1}$$

其中 $o_{\le t}$ 为已有观察，m_t 为当前记忆状态，a_t 可以是检索、执行、通信或终止等动作。该式仅用于统一描述，并不限定策略必须通过训练获得。多智能体系统在此基础上引入不同主体之间的信息交换、任务依赖和调度规则。

因此，多智能体与单智能体之间并不存在只由数量决定的能力分界。一个具有检索和执行反馈的代理可以完成较复杂的循环，多个代理也可能只是在重复相同推理。多代理的实际价值取决于分解后的任务是否具有互补性、角色能否获得不同观察，以及协调开销是否小于分工收益。本文在后续比较中将基础模型、工具能力、协作结构与计算预算分别处理，避免把系统层面的所有改进都归因于代理数量。

3 知识增强与长期记忆

3.1 检索粒度与知识组织

科研任务需要处理的资料既包括局部事实，也包括跨文献的主题、方法和争议。不同查询所需的检索粒度并不相同：查找实验参数通常需要原文片段，比较多项研究则需要整合其对象、条件与结论。RAG 的原始研究将文档检索与条件生成结合，为利用外部知识提供了通用途径[3]。其优势在于资料可以更新，生成结果也有机会回到明确来源；不足是局部相似性并不总能覆盖问题所需的全部信息。当答案依赖多处条件时，单个高相似片段可能不足以支持完整判断。

层次检索通过改变信息的组织尺度缓解这一问题。RAPTOR 递归地对文本片段进行聚类和摘要，构建包含不同抽象层次的树，使检索同时接触细节与较高层概括[21]。与直接增加返回片段数量相比，这类方法能够显式表示信息的概括关系。但摘要层次越高，压缩越明显，关键限定与原始证据之间的距离也越大。因此，层次摘要适合定位主题和组织阅读，涉及具体数值或争议判断时仍需向下追索。

GraphRAG 采用另一种组织方式：从文本中抽取实体及关系，通过社区发现和社区摘要形成全局信息结构[20]。其主要价值是支持面向整个语料的概括，特别是相关信息分布在多个文档中的问题。相较于树结构，图能够容纳更丰富的交叉关系，但也增加了实体消歧、关系抽取与更新维护的复杂度。RAPTOR 与 GraphRAG 因而分别强调层次概括和关系连接，并非彼此完全可替代的索引方案。图3从信息组织角度比较了这些路线与任务记忆的差别。

3.2 检索决策与证据支持

除索引结构外，检索何时发生、结果如何被筛选，同样影响生成质量。Self-RAG 使用经过训练的反思标记，控制是否检索，并评价材料相关性、生成内容的支持程度及回答质量[22]。与固定返回若干片段的流程相比，这一路线把检索需求和证据使用纳入生成决策。它也说明“反思”可以具有不同技术含义：Self-RAG 包含专门训练和控制标记，并不是在任意模型之后添加一句检查

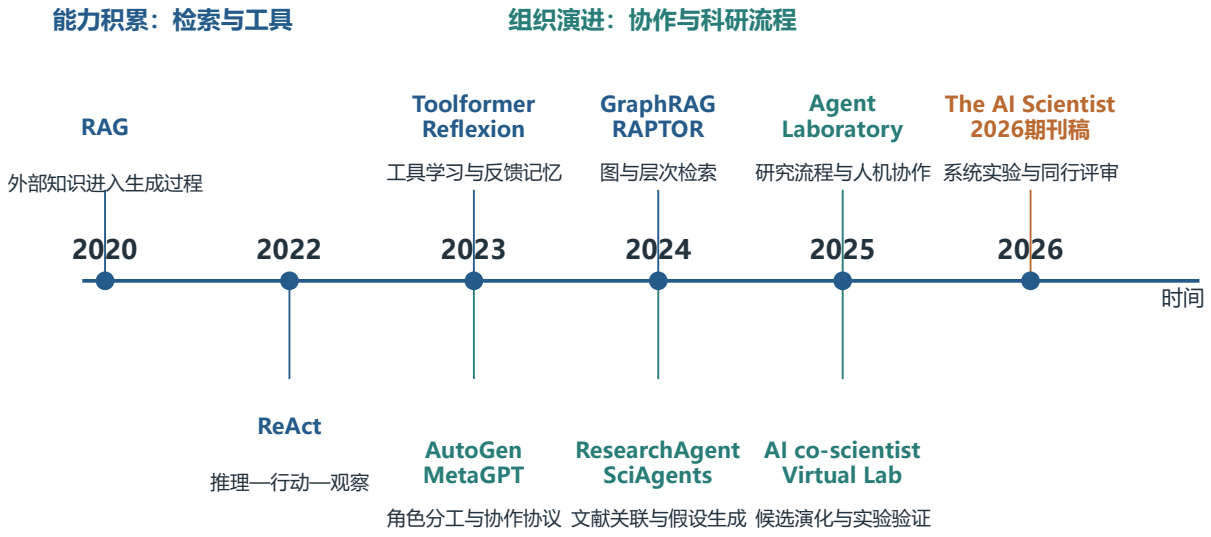


图 1 科研智能体相关能力与系统的代表性发展脉络。依据文献[3–7,10,11,14–18,20,21]整理。基础工作按首次报告年份归类，2026 年节点指期刊报告；时间节点为离散排布，不以间距表示持续时间。图中仅列代表工作，不表示其他路线在相应年份缺失。

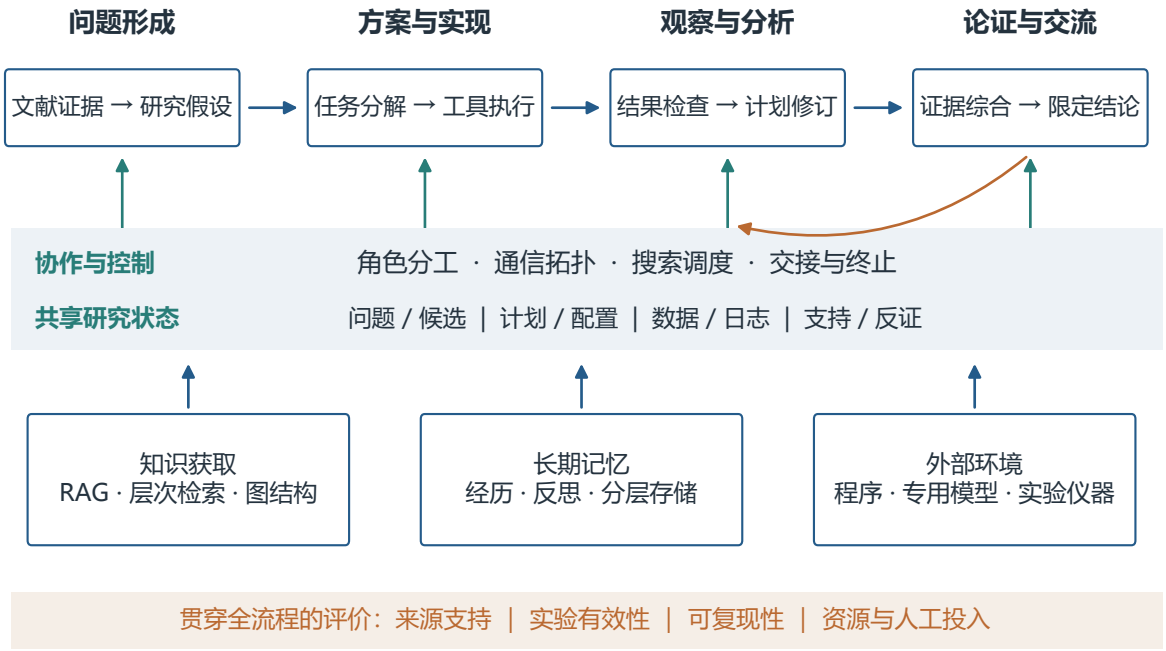


图 2 科研工作流与支撑机制的对应关系。综合检索增强、分层记忆、代理交互与自动科研流程[3,5,6,13,17]绘制。上部为研究阶段，中部为协作及共享状态，下部为知识、记忆和环境支撑；评价贯穿整个过程。该图为综述性归纳，箭头不表示测得的效果大小。

提示就能获得相同机制。

面向科研的证据使用还需要区分相关、支持与充分三个层次。某段文字可以与问题相关，却只讨论另一种数据设置；即使支持一个局部命题，也未必足以支持更广泛结论。因此，检索输出需要保留对象、实验条件和结论范围，生成阶段则应维持这些限定。在检索结果互相矛盾时，较合理的输出是呈现差异及其可能来源，而非强行综合成一致意见。这一要求使科研 RAG 更接近文献分析过程，而不仅是为回答补充背景材料。



图 3 外部知识与研究记忆的组织方式。左、中两部分分别根据 RAG、RAPTOR 及 GraphRAG 的机制绘制[3,20,21]；右部综合 MemGPT、Reflexion 与科研状态管理需求[11,13]，为本文分析示意，不代表原方法使用了完全相同的状态字段。各结构不按存储量或性能比例绘制。

扩大上下文窗口可以减少部分切分与多次检索的需要，但不能完全代替上述过程。Lost in the Middle 显示，在所测模型和任务中，相关信息的位置会影响长上下文利用效果[23]。这一发现不应机械外推到所有新模型，却说明上下文容量与有效信息利用需要分别评估。在实际系统中，长上下文、检索筛选和多轮核查可以互补；方法选择应结合资料规模、查询类型及允许的调用预算。

3.3 经历记忆、反思与分层存储

外部知识主要描述已有研究，任务记忆则保存项目进行过程中产生的观察、计划和判断。Generative Agents 通过记忆流、相关经历检索、反思与规划，展示了代理如何在较长时间内维持行为连续性[12]。这一设计的重要启发是，历史信息不必全部进入当前上下文，而可以根据相关性、时间及重要程度有选择地调用。但其评价主要针对社会行为的可信感，迁移到科研任务时，需要重新定义哪些经历值得保留，以及怎样处理后来出现的反证。

Reflexion 将环境或评价器的反馈转化为语言反思，并保存在经历记忆中，用于改善后续尝试[11]。它不通过更新模型权重完成适应，而是改变下一次行动所依据的上下文。这使失败尝试能够成为后续计划的输入，适合程序调试和具有明确反馈的任务。反思的有效性同时依赖反馈质量：如果评价器无法识别错误，文字总结可能只是把错误解释得更完整。因此，反馈信号、反思过程和记忆写入规则需要作为相互关联的设计选择讨论。

MemGPT 将上下文管理类比为分层存储，通过显式操作在当前窗口与外部存储之间调度信息[13]。相较于持续扩展提示或反复压缩全部历史，分层设计能够把信息保留与当前访问分开。这一机制主要解决容量与调度问题，是否形成可靠科研记录，还取决于存入了何种内容。观察、解释和计划具有不同地位：实验得到的数值是观察，对数值的原因分析是解释，下一轮配置属于计划。若三者在摘要中混合，后续代理就难以判断哪些内容已经测量、哪些仍待检验。

3.4 知识与记忆的协同维护

从技术实现看，知识与记忆都可以采用文本、向量或图表示，二者的核心差异在于来源和更新方式。论文知识随着外部资料变化而更新，项目记忆则随着研究活动逐步积累。将二者相连，有助于解释某次实验为何采用特定方案，也能在新的文献出现时识别需要复查的旧判断。然而，无来源区分的统一文本库容易产生循环引用：代理先写入推测，后续又检索到该推测并把它当成外部支持。因而，共享存储不应取消原始资料与派生解释之间的区别。

对科研任务而言，记忆质量更适合用关键判断能否被重建来衡量。与研究方向变化、异常结果和结论修正有关的记录，应保留其条件与依据；重复性的接口说明与常规状态则可以适度压缩。这样既能控制上下文开销，也避免把所有历史等

量保存。表1总结了主要路线的处理对象及适用边界。综合来看，知识增强与记忆机制的共同趋势，是由单纯“增加可见文本”转向对信息粒度、来源和使用时机进行管理。

4 多智能体协作与研究过程控制

4.1 角色分工与通信拓扑

多智能体系统将复杂研究分配给可区分的任务主体，并通过消息或共享状态协调活动。角色可以按专业知识划分，也可以按研究阶段或工具权限划分。前者有利于跨学科问题讨论，后者便于明确交付物和验收标准。两种划分可以结合，但角色名称本身不能解释收益：其作用需要通过获得的信息、承担的动作和对其他主体的约束来说明。

图4归纳了三种常见组织形式。流程型协作沿既定依赖传递结果，适合文献整理、实现与核对等顺序较清楚的任务；中心调度型协作由协调者分配子任务和整合输出，便于管理资源及处理分支；讨论型协作允许主体交换候选与批评，更适合尚未固定研究路径的探索。AutoGen 支持通过可编程交互构造多种模式[5]，MetaGPT 则强调标准化操作流程及中间产物[14]。实际系统往往同时采用多种拓扑，不能仅凭一张角色图认定其全部控制方式。

通信结构影响系统效率，也影响错误传播。流水线可以减少无关讨论，但上游遗漏可能被下游连续接受；中心调度便于统一判断，却形成对协调者的依赖；自由讨论扩大了信息交换范围，也增加重复消息、状态不一致和过早形成共识的可能。在 n 个代理每轮两两通信的理想化设置中，T 轮对应的有向消息数为 $Tn(n-1)$。实际费用还取决于消息长度、工具调用和重试次数，但这一关系已经说明通信开销需要随协作规模一起评价。

4.2 任务分解与标准化交付

将研究目标拆成子任务，既是能力分配问题，也是约束传递问题。如果任务定义只有“完成实验”或“检查结果”，后续代理仍需自行猜测哪些数据、指标和条件应被保留。MetaGPT 将标准化操作程序嵌入角色协作，使中间产物成为后续工作的共同依据[14]。科研系统可以借鉴这一思路，将文献证据、实验方案、运行记录和结论依据作为不同交付对象。

标准化的作用并不是增加固定格式，而是减少信息在交接中的损失。检索环节应说明来源支持何种判断，实验环节应保留比较条件及配置，分析环节应区分观测结果与解释，报告环节则需要维持结论范围。只有这些对象能够相互对应，检查者才能判断问题来自任务定义、程序实现还是结果解释。相反，若交付仅包含经过润色的摘要，流程虽然更简洁，返工和审计却会更加困难。

任务分解还需适应研究的不确定性。对目标明确的复现任务，固定流程通常有利于控制变量；对假设探索任务，过早固定步骤可能限制新证据引起的方向调整。因此，流程约束宜优先固定研究原则和交付内容，对探索路径保留一定灵活性。这种区分能够兼顾研究过程的开放性与实验比较的可解释性。

4.3 反馈、反思与辩论的作用条件

ReAct 将外部行动观察纳入推理过程，为科研代理调用检索和程序工具提供了基本交互模式[4]。Reflexion 进一步让反馈影响后续尝试[11]，多代理辩论则通过交换不同回答与理由，使系统在部分推理和事实任务中改善结果[24]。这些工作共同说明，增加修订机会能够带来收益，但收益来源并不相同：可能来自新证据、错误定位、候选多样性，也可能来自更多推理样本。

因此，需要区分外部反馈与语言层面的再评价。编译器可以判断部分程序错误，测试可以检验预先规定的行为，实验仪器则提供关于物理对象的观察；模型批评主要评价已有材料中的合理性和一致性。它们都可能有用，但能够支持的结论范围不同。Huang 等对内在自我纠错的研究表明，没有可靠外部反馈时，所测推理任务的修订并不稳定[25]。这与辩论方法在部分任务上的正向结果并不矛盾，因为任务、信息来源和计算设置不同。

多角色的独立性也需要具体判断。使用相同基础模型并不必然使协作无效，但共享资料和错误前提会限制检查增量。检索者寻找支持材料，反例搜索者专门寻找相反证据，执行者独立重算结果，比多个角色重复评价同一段文字更容易形成互补信息。由此可见，协作设计的重点在于构造有意义的差异，而非仅增加身份设定。

4.4 从固定流程到搜索调度

当研究存在多个候选方案时，协作还需要决定资源应投向哪条路径。The AI Scientist-v2 引入实验管理代理和渐进式树搜索，将候选实现、调试及改进组织为分支探索[26]。AI co-scientist 则通

表 1 知识增强与记忆机制的比较。外部知识组织和项目经历管理服务于不同目标，不作统一性能排名。

路线与代表方法	核心机制	主要适用任务	需要关注的限制
片段检索：RAG[3]	根据查询检索相关文档或片段，条件化生成	事实查询、参数定位、材料更新	相似性不等于证据支持，多处条件可能被遗漏
层次检索：RAPTOR[21]	递归聚类与摘要，跨抽象层检索	长文理解、跨段综合	高层摘要压缩细节，需要保留回溯关系
图检索：GraphRAG[20]	实体关系、社区及社区摘要	主题分析、全局信息综合	抽取误差、实体歧义与索引维护成本
自适应检索：Self-RAG[22]	训练反思标记，控制检索并评价生成支持	按需检索、事实性与引用改进	依赖训练与评价设计，不能等同于一般提示反思
经历与反思记忆[11,12]	检索历史经历，将反馈写入后续上下文	长期规划、重复尝试与错误修正	反馈失真可能固化错误，原始观察与解释需区分
分层存储：MemGPT[13]	在当前窗口和外部存储间调度	长对话、持续任务与信息保留	信息可访问性与记录真实性需要分别检验

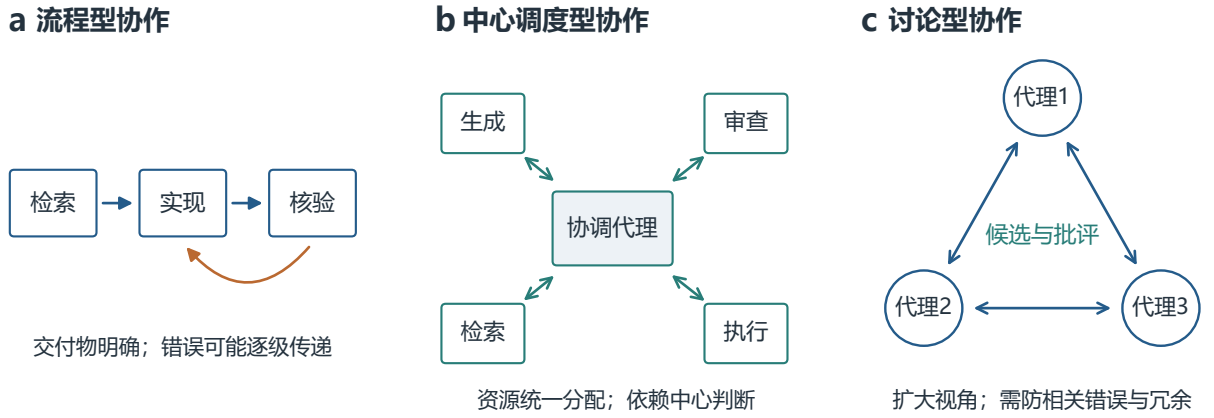


图 4 多智能体协作的三种基本组织形式。依据代理交互、标准化流程与多代理辩论研究归纳[5,14,24]。节点表示功能主体，边表示允许的交互；图示用于分析组织差异，不将某一框架限定为单一拓扑。

过假设比较和演化调整候选集合[18]。前者的反馈更多来自可执行实验与评价，后者更侧重假设和研究建议的质量。二者分别展示了实现空间与假设空间中的搜索控制。

搜索带来更广的探索机会，也引入候选选择偏差。若多次尝试始终围绕测试集成绩选择方案，最终报告可能高估泛化能力；若候选排名仅依赖同类模型判断，则可能偏好容易表述、符合常见叙事的想法。因此，搜索效率、研究质量和评价有效性应分别报告。对科研系统而言，保留候选淘汰原因、失败尝试和最终选择依据，比单独展示最优分支更有助于理解其实际能力。

5 科研应用与代表性系统

5.1 文献综合与研究问题形成

文献工作既是科研智能体较易进入的场景，也是后续研究的知识基础。PaperQA2 将搜索、文献处理、证据整理与带引用的回答联系起来，并针对检索、综合及矛盾识别设计评价[27]。相较于仅在给定段落上问答，这类系统需要决定继续搜索何种材料，以及何时已有证据足以回答问题。研究中的矛盾识别结果还说明，资料综合不仅涉及归纳共识，也涉及寻找不能被同时接受的表述。这些任务使评价从答案流畅性转向材料覆盖与来源支持，具有直接的科研实用价值。

ResearchAgent 以核心论文为起点，结合学术关系和概念知识生成问题、方法与实验构想，再通过评审代理的反馈迭代修订[15]。SciAgents 进一

步将本体知识图谱、语言模型与多主体讨论结合，用于探索材料相关概念之间的联系[16]。二者分别强调围绕论文展开的构思和图结构支持的跨概念关联。这类方法为从已有知识中发现研究切入点提供了可操作途径，也使图组织的价值从信息检索延伸到候选生成。

不过，构思质量仍有多个层次。新颖性关注与已有工作的差别，合理性关注机制或方法是否自洽，可检验性则要求提出可以实施的区分手段。人工或模型评价可以检验候选是否值得进一步研究，但不能代替候选真正实施后的证据。因此，文献与假设系统最适合被理解为研究准备和探索工具，其产出需要在实验设计阶段继续筛选。这一定位能够保留系统的创造性价值，也避免把构思评分直接解释为发现成功。

5.2 计算实验与端到端研究

计算科研具有数据、程序和指标可被统一工具链处理的特点，是端到端研究的重要试验场。The AI Scientist 早期系统将创意生成、代码修改、运行、分析、写作与模拟评审连接起来[28]。其预设模板限定了初始研究空间，但也降低了环境配置与基础实现的不确定性，便于集中考察想法生成和实验迭代。第二版系统减少对人工代码模板的依赖，使用实验树搜索扩展候选，并引入视觉语言反馈改善图表与呈现[26]。从固定模板到搜索式实验管理，反映了自动科研由局部修改向更开放实现空间的发展。

2026 年的期刊报告同时研究聚焦模式与开放模式，并进一步讨论自动评审及实际工作坊评审[6]。这比仅由系统内部评价生成论文提供了更多外部参照。但工作坊个案的评价范围、主题设置和接受条件仍需与通常意义上的广泛科学贡献区分。早期系统、第二版与期刊报告属于同一研究脉络，不能作为三次独立的全面能力验证累加。

Agent Laboratory 采用不同的协作定位：从人提供的研究想法出发，组织文献、实验与报告，并允许在各阶段引入人的反馈[17]。其价值在于把自动化目标与研究者的已有目标相结合，而不要求系统独立决定所有问题。原文同时比较模型后端、人工评价和不同参与方式，报告了特定设置中自动总体评分 6.1/10 与人工 3.8/10 的差异。这一结果表明，研究报告的可读性、实验质量和评审模型偏好需要分开评价。对于协作式工具，实际帮助可能体现为降低实现负担，也可能体现为研究者更容易发现计划中的问题，因而仅用最终论文评分还不能完整衡量其效用。

5.3 假设搜索与跨学科研究协作

AI co-scientist 围绕专家给定的目标，组织生成、反思、排序、演化等功能代理，通过候选比较与迭代形成研究建议[18]。这种设计将计算资源用于扩大和修订假设空间，与按既定方案执行一次实验不同。其排序反馈有助于筛选候选，但排名反映的是比较标准下的相对优势，不能直接解释为命题成立的概率。

该研究在药物再利用、肝纤维化靶点及细菌基因转移机制等方向报告验证案例[18]。各案例的证据性质不同：细胞或类器官结果提供特定实验体系中的支持，与尚未公开的实验机制相符合，则体现另一种知识推断能力。这些案例说明候选生成可以与真实科研检验衔接，但其一般化范围仍取决于问题选择和后续实验。

Virtual Lab 以负责人代理和专业代理组成研究会议，由人类提供高层反馈，将蛋白质语言模型、结构预测和分子能量评价整合到纳米抗体设计流程[7]。论文选择 92 个候选进行实验表征，既呈现了有前景的候选，也显示计算指标与实际功能的差异。其中 78 个候选具有更高的相应结构置信度指标，60 个具有更优的 Rosetta 结合能，但不同亲本系列的实际结合表现并不一致。这说明专用计算模型、代理组织和实验验证承担不同作用，不能仅凭代理参与就把所有收益归为 LLM 推理。对跨学科研究而言，多代理更有意义的贡献是组织已有专长和工具，并使不同研究环节形成可追踪联系。

5.4 专业工具与实体实验

ChemCrow 将 18 种专业工具与语言模型结合，用于化学相关问题、合成规划及实验任务[29]。专门工具补充了基础模型难以可靠完成的化学计算、检索和执行能力。这一设计体现了通用代理与领域工具之间的分工：模型负责解释目标和选择步骤，工具负责具有明确输入输出的专业操作。工具覆盖范围、输入表达和输出解释因而与模型能力同样重要。

Coscientist 进一步将网络检索、装置文档、代码执行和实验设备整合，展示化学实验从自然语言要求到执行与产物检查的过程[19]。图5左侧概括其关键步骤，右侧保留原论文的实验谱图。在这一流程中，装置文档能够帮助修正调用方式，色

谱与质谱则提供区别于语言评价的产物证据。研究因此不只依赖系统是否声称完成任务，还可以检查实验输出与参照物之间的关系。

实体反馈提高了某些判断的可检查性，也使资源与操作约束更加突出。Coscientist 的部分物理操作仍由人工完成，可探索的试剂和设备范围也由实验设置限定[19]。因此，系统应在明确资源边界内评价，不宜把特定装置上的成功直接扩展为开放实验室中的普遍自主能力。与纯计算场景相比，实体系统更需要在计划阶段考虑操作权限、异常中止、测量噪声和验证成本。

5.5 不同科研路径的比较

表2从研究对象与反馈方式总结代表系统。文献与构思系统的主要产物是证据综合和候选问题，计算系统便于反复执行，实体系统则可以获得更直接的经验观察。不同路线的自动化覆盖与验证深度相互独立：覆盖更多阶段可以减少人工交接，但也增加错误跨阶段传播的机会；加入实验测量能够检验具体命题，却仍然依赖有效的对照与解释。因此，更有意义的比较不是给系统排列统一自主等级，而是说明它们在哪些条件下推进了哪些研究活动。

6 评价方法与实证证据

6.1 评价对象与基准差异

科研智能体的评价首先需要明确系统应交付什么。文献任务可以检查回答与来源之间的支持关系，代码任务需要检查程序及其输出，开放研究还涉及问题价值、实验设计和结论范围。这些目标不能被一个通用文本分数完全覆盖。表3将本文涉及的评价工作按对象整理，说明其能够回答的问题。

ScienceAgentBench 从 44 篇同行评审论文提取 102 项数据驱动任务，以独立程序及执行结果作为统一输出，并区分有效执行率（valid execution rate，VER）和任务成功率（success rate，SR）[30]。前者检查程序是否运行并正确保存输出，后者检查是否达到各任务的具体标准。这一划分使“可以执行”与“完成科学计算目标”之间的差异能够被直接观察。它仍主要评价研究工作流中的任务，不是对完整科学发现的统一验收。

RE-Bench 提供 7 个开放机器学习研究工程环境，并纳入人类专家尝试作为参照[31]。其结果显示，人与代理的相对表现会随总时间预算改变：短预算下代理具有较高搜索吞吐，较长预算下人的收益增长更明显。这一发现说明，“系统是否超过专家”需要同时说明任务、预算和尝试分配。将不同资源条件的结果合并为单一能力标签，会掩盖时间、重试和经验积累的作用。

6.2 执行率、任务成功率与资源成本

图6选取 ScienceAgentBench 中两个模型在三种框架下的结果。其中 Self-Debug 通过执行反馈修订程序，OpenHands CodeAct 提供更广的交互动作；费用为原论文记录的应用程序接口（application programming interface，API）调用支出。原文每项任务独立运行三次，依次按 SR、VER、CodeBERTScore 和较低费用择优，最后汇总入选运行；下述结果因而不同于单次运行均值。在不提供专家知识的条件下，Claude 3.5 Sonnet 结合 Self-Debug 的有效执行率为 92.2%，任务成功率为 32.4%；GPT-4o 对应结果为 83.3% 和 22.6%[30]。差距说明程序错误被排除之后，仍有任务理解、数据处理和方法选择等问题需要解决。因此，执行反馈的价值不能仅由运行成功推断，也不能因为程序可执行就把其输出视为研究结论。

成本比较还揭示了流程复杂度与收益并不总是同步增长。Claude 3.5 Sonnet 使用 OpenHands 时，原文平均 API 费用为 0.958 美元、成功率 21.6%；Self-Debug 对应为 0.057 美元与 32.4%[30]。这组结果支持在该任务和模型设置下比较更简洁的执行反馈方案，而不能推广成某一框架始终更优。其启示在于，工具种类、动作空间与交互协议会影响模型能否有效利用资源，协作机制的改进应当相对于相应的简单基线评价。

6.3 多代理失败与过程审计

最终分数可以揭示系统间差异，却不总能解释失败原因。MAST 将多代理失败归纳到规范与系统设计、主体间失配和任务核验等方面[32]。对于科研系统，这些问题可能体现为研究目标被误解、交接丢失条件、代理重复工作或过早宣布完成。识别失败发生的位置，有助于判断应当改善模型能力、通信协议还是验收规则。

Luo 等针对自动科研设计受控实验，研究基准选择、数据泄漏、指标误用及事后选择等方法学风险[8]。图7比较其审计模型仅阅读论文与同时获得日志、代码时的结果。在 100 个、各类正负样本均衡的审计案例上，总体准确率由 55% 提高至 82%。这一比较说明，研究过程材料能够提供最终论文中缺失的信息。但部分缺陷由原作者注入，

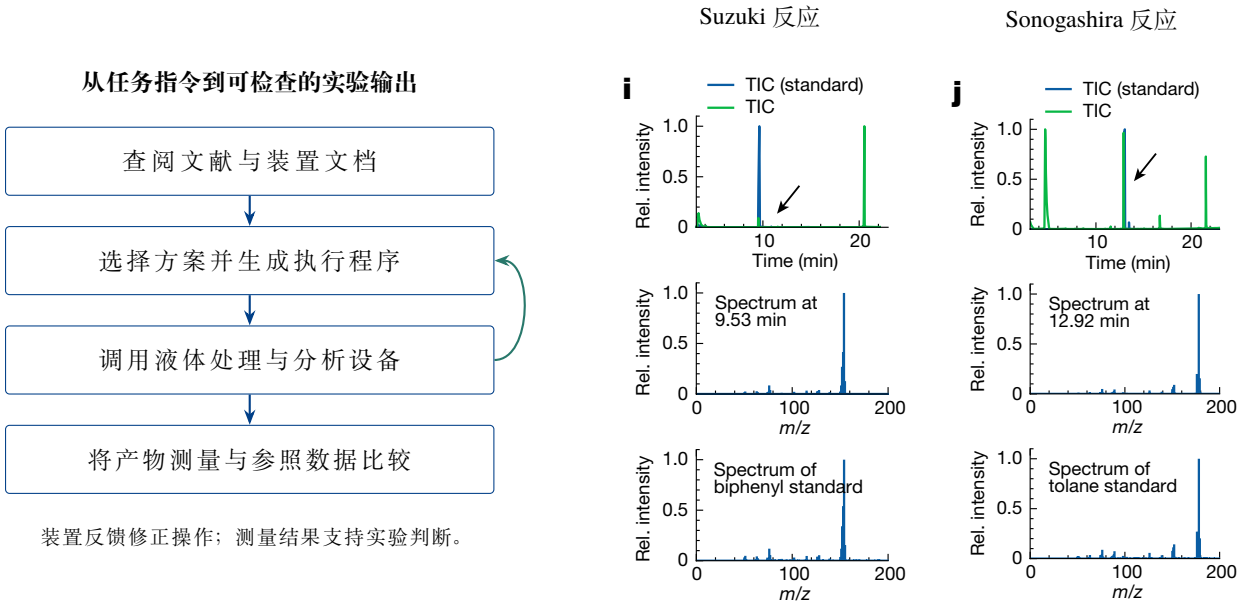


图 5 科研代理与实体实验验证的衔接。左部依据 Coscientist 流程归纳[19]；右部摘自 Boiko 等原图 5i、5j，分别包含色谱及对应质谱与标准参照。图中曲线、坐标与数值保持原样，仅提取面板并调整排列。原图版权为作者，依据CC BY 4.0转载；数据不是本文实验结果。

表 2 代表性科研系统的主要组织方式与证据来源。不同报告之间的任务、模型、工具和人工参与不同，不作统一成绩比较。

系统	研究对象与组织重点	反馈或验证方式	主要解释边界
PaperQA2[27]	文献检索、综合与矛盾识别	文献任务基准及专家比较	文献综合能力不等同于实验发现能力
ResearchAgent / SciAgents[15,16]	论文关系、概念图谱与迭代构思	评审反馈、人工或模型评价与案例	候选质量仍需后续实施和检验
The AI Scientist 系列[6,26,28]	模板研究、实验搜索与论文生成	程序实验、自动评审及工作坊案例	同一研究系列；个案评审有其适用范围
Agent Laboratory[17]	人给定想法上的研究协作	人工评价、后端与参与方式比较	人工帮助及评价差异需单独报告
AI co-scientist[18]	多候选生成、比较和演化	专家反馈与部分生物医学实验	排序不是命题真值，验证类型存在差异
Virtual Lab[7]	跨学科会议与专用计算工具整合	纳米抗体设计后的实验表征	计算指标、表达与功能为不同评价目标
ChemCrow / Coscientist[19,29]	专业工具调用与实体执行	专家检查、仪器观察及产物分析	工具覆盖、装置条件和人工操作限制范围

因而结果衡量的是受控材料下的识别能力，并不估计实际科研中的缺陷比例。

这也说明可复现材料不仅服务于复查数值，还能帮助理解研究选择。例如，日志可以显示是否多次比较测试成绩后仅报告最佳结果，代码可以暴露训练与测试数据的实际使用方式。对自动科研的审查因此需要适当延伸到论文之外。与此同时，原始记录应有清楚的时间与对象关联，避免大量无组织日志反而增加理解成本。

6.4 协作收益的对照设计

要识别多智能体协作的独立贡献，需要尽量控制基础模型、资料、工具权限、总预算和人工帮助。单智能体基线也应获得相应的检索、推理与重试机会，而非只允许一次回答。否则，观察到的提升可以归因于整个系统，但难以进一步确定来自角色分工、额外样本还是更多工具调用。

功能消融可以进一步区分这些因素。例如，在保留预算的条件下合并角色，检验通信是否必要；在保留角色数的条件下取消独立证据检查，检验核验机制的贡献；在长期任务中关闭来源或版本

表 3 代表性科研评价工作的任务与测量对象。各基准衡量不同能力，不能将分数直接拼接为综合排行榜。

评价工作	任务或材料	主要测量对象	适用范围
PaperQA2 / LitQA2[27]	真实文献检索、综合与矛盾识别	文献问题回答和专家比较	信息研究能力，非实体实验有效性
ScienceAgentBench[30]	102 项任务，来自 44 篇论文	任务成功、有效执行、代码及成本	数据驱动工作流中的程序任务
RE-Bench[31]	7 个研究工程环境及专家尝试	不同时间预算下的任务收益	开放工程任务，不等同于全部科研活动
MAST[32]	多代理执行过程及失败案例	规范、协调与核验失败分类	失败定位框架，不是科学产出通用评分
科研过程审计[8]	受控任务、论文、日志和代码	方法学缺陷识别与材料贡献	部分缺陷受控注入，不代表自然发生率

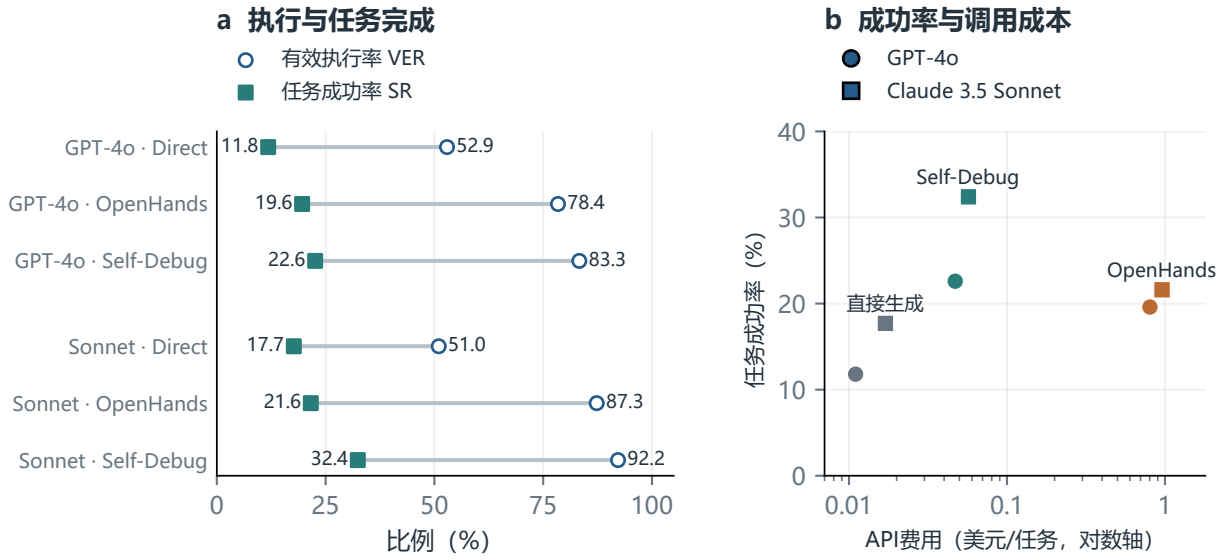


图 6 ScienceAgentBench 中执行、成功与成本的关系。数据重绘自文献[30]表 3（固定 v3，PDF 第 8 页），选取 GPT-4o 与 Claude 3.5 Sonnet 在全部三种框架、无专家知识条件下的六组配置；共 102 项任务，每项三次独立运行后择优汇总。左图为有效执行率 VER 与任务成功率 SR，右图为 SR 与平均 API 费用，费用轴为对数轴。模型版本和费用均对应原论文时期；原表点估计未提供本图可用的重复运行区间，未添加误差条。

区分，观察错误是否更容易被重复使用。这些设计还需要说明删除组件之后资源如何重新分配。结合失败分布、人工修改和中断率，才能更全面地判断协作是否改善了实际研究过程。

7 综合讨论与研究展望

7.1 由流程自动化转向研究有效性

前述研究表明，知识增强、长期记忆与多代理协作分别处理不同瓶颈，系统能力来自其配合，而不是某个机制名称。更强检索可以改善问题所依据的材料，长期记忆可以减少反复重建上下文，协作则可以组织专业工具与检查过程。这些进展确实扩大了自动科研的任务范围。然而，跨阶段组合也使局部错误更容易影响后续选择，因此评价对象应从单步回答继续扩展到研究依赖关系。

本文认为，科研系统值得长期保留的基本对象，应是具有明确依据和适用范围的研究判断。每项关键判断关联其来源、实验条件和反证，后续任务才能知道哪些内容可以继续采用、哪些仍需验证。当数据处理被修正时，系统应识别受影响的结果与结论，而不是只重新生成一篇措辞一致的报告。这一要求将知识图谱的关联能力、记忆的版本维护和协作的返工控制联系起来，也为长期科研评价提供了更具体的观察对象。

7.2 知识组织与研究记忆的互补关系

课堂中关于图式知识组织和自主记忆的讨论，反映了两种不同需求。图结构适合相对稳定的概念关联和跨文献主题，任务记忆则需要快速容纳尚不确定的尝试、解释与异常。若全部内容

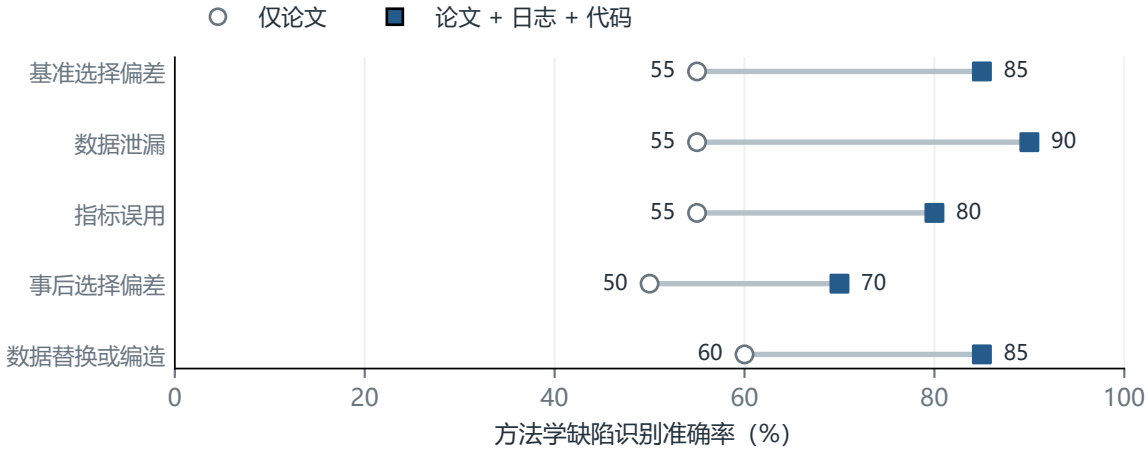


图 7 过程材料与方法学缺陷识别。重绘自文献[8]第 6.2 节与表 11（固定 v2，PDF 第 16–18 页）。每类 20 例，含 10 例阳性和 10 例阴性；部分阳性通过受控修改构造。审计模型为 gemini-2.5-flash-preview-05-20。图示为准确率点估计，未补造不确定区间；日志与代码在同一条件中同时加入，不能分别归因。

都按稳定知识处理，新假设可能过早固化；若只保留自由对话，重要关系又难以持续利用。因此，二者结合的关键不是采用相同存储格式，而是明确什么信息在何种条件下可以转入较稳定的知识状态。

一个可行方向是保留观察、解释和结论之间的依赖，让反证能够改变状态而不抹去历史。常规记录可以压缩，影响研究方向的判断则保留更完整依据。图8给出了本文的综合理解：检索和候选生成扩展探索范围，区分性实验提供新观察，记忆更新再影响下一轮选择。这一路径同时强调信息获取与认识修订，能够避免把已有判断在知识库和代理之间反复传递当成新的支持。

7.3 探索效率与验证成本的共同约束

候选生成速度提高之后，系统瓶颈可能从提出想法转移到判断哪些想法值得继续研究。更多代理能够产生更多方案，却未必增加实验资源或领域审查能力。因此，研究预算需要同时覆盖探索与核验，并考虑不同候选能否被现有数据或低成本实验有效区分。对于验证代价较高的问题，单纯增加候选数可能增加筛选负担，而不是提高科研效率。

验证也不应被简化为与已有共识的一致程度。新假设往往超出现有结论，审查的作用是确认事实基础、逻辑关系与可检验条件，而非要求所有推测都已被证明。允许系统明确保留“尚待检验”的判断，能够在探索空间与科学审慎之间形成更合理的平衡。相应地，评价应分别报告新颖性、可行性和证据支持度，不宜由一个语言偏好分数替代。

7.4 协作规模与人工参与的任务适配

科研多代理更适合任务依赖复杂、工具异质且交付可检查的场景。对于局部事实检索，增加角色可能主要增加通信成本；对跨学科设计，不同功能主体与专用工具之间的配合则更有价值。因此，协作规模宜由任务结构和实际消融决定。未来系统可以根据当前不确定性调整参与角色，而非从开始到结束维持固定人数和相同讨论模式。

人的作用也需要从简单的“是否介入”进一步细化。问题选择、对照设计、异常解释和结论范围通常具有较高判断价值；常规检索、运行和材料整理则更适合交由工具处理。在前者设置清晰检查点，有助于把有限专家时间用于最影响研究有效性的环节。同时，评价需要记录人工输入与修改程度，才能判断系统是在替代劳动、放大已有能力，还是把工作转移到了未被计量的审查过程。

7.5 长期评价与本文局限

真实科研往往没有立即可知的唯一答案，目标也可能随新证据改变。短任务基准适合比较局部能力，但对长期研究中的错误恢复、方向调整和失败价值覆盖不足。未来评价应保留跨阶段轨迹，并在可行时加入独立执行者、预先保留任务及后续复查，考察系统能否在新证据下更新既有结论，而不只是完成一次既定流程。

本文以知识、记忆和协作为主要分析线索，没有完整覆盖训练式多代理优化、基础模型训练和所有学科应用。所引系统的模型、任务、工具与人

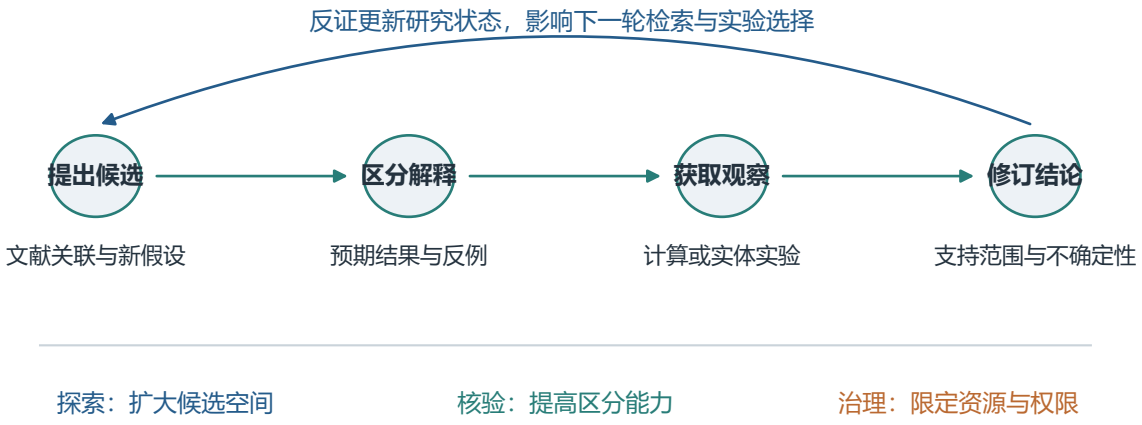


图 8 基于综述形成的研究闭环理解。候选生成、区分解释、外部观察与结论修订相互联系，探索、核验和资源治理分别提供不同约束。该图为本文讨论框架，未声称已经实现或经新实验验证。

表 4 由本文分析形成的可检验研究议题。以下为研究设计建议，未报告本项目新实验。

研究议题	可采用的对照设计	需要观察的结果
来源与状态管理的贡献	相同工具和预算下，比较无类型记忆与来源、状态可区分的记忆	错误重复、反证利用、关键判断可重建程度
协作结构的必要性	保留调用预算和权限，比较单代理、固定分工及动态调度	完成质量、通信开销、中断与返工分布
独立检查的有效性	保留角色数，改变检查者能访问的原文、数据与执行记录	缺陷识别、误报、修正成功和检查成本
人机协作的价值位置	记录并比较目标、实验设计及结果解释阶段的人工介入	质量改善、专家时间、修改量及研究者负担

工参与不同，本文不进行跨论文效应合并。重绘数据图仅呈现原论文内部比较，转载谱图保留原始实验属性，均未作为本项目新结果。此外，早期模型上的数值表现不代表当前系统水平；其揭示的评价问题需要在新模型和新任务中继续检验。

8 结语

大语言模型驱动的科研多智能体系统，正在将知识获取、工具执行和研究交流整合到持续工作流中。检索增强改善外部知识的访问，层次与图组织支持跨材料综合，反思和分层记忆延续任务经历，协作协议与搜索调度则组织多个主体在研究过程中的配合。代表系统展示了从文献综合到计算实验、再到实体测量的多种路径，也说明不同科研活动需要不同形式的反馈与验证。

综合现有证据，协作规模、自动化覆盖和科研可信度应分别描述。可靠系统需要保留来源、实验条件、失败尝试及修订依据。知识与研究状态的协同维护、探索和验证资源的联合分配，以及关键节点的人机协作，是值得持续研究的方向。科研智能体的价值，最终应体现为更有效、更可复查的研究过程与产出。

参考文献

[1] Zheng T, Deng Z, Tsang H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C]//Proceedings of EMNLP. 2025: 17733–17750. DOI:10.18653/v1/2025.emnlp-main.895.

[2] Wei J, Yang Y, Zhang X, et al. From AI for Science to Agentic Science: A Survey on Autonomous Scientific Discovery[EB/OL]. 2025. arXiv:2508.14111v2.

[3] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. 2020. arXiv:2005.11401v4.

[4] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//International Conference on Learning Representations. 2023. arXiv:2210.03629v3.

[5] Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[EB/OL]. 2023. arXiv:2308.08155v2.

[6] Lu C, Lu C, Lange R T, et al. Towards end-to-end automation of AI research[J]. Nature, 2026, 651: 914–919. DOI:10.1038/s41586-026-10265-5.

[7] Swanson K, Wu W, Bulaong N L, et al. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies[J]. Nature, 2025, 646: 716–723. DOI:10.1038/s41586-025-09442-9.

[8] Luo Z, Kasirzadeh A, Shah N B. The More You Automate, the Less You See: Hidden Pitfalls of AI Scientist Systems[EB/OL]. 2025. arXiv:2509.08713v2.

[9] 郑逸宁, 余镇, 李不凡, 等. 大语言模型的工具使用综述 [J]. 自动化学报, 2025, 51(11): 2371–2386. DOI:10.16383/j.aas.c240793.

[10] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: Language Models Can Teach Themselves to Use Tools[EB/OL]. 2023. arXiv:2302.04761v1.

[11] Shinn N, Cassano F, Berman E, et al. Reflexion: Language Agents with Verbal Reinforcement Learning[EB/OL]. 2023. arXiv:2303.11366v4.

[12] Park J S, O'Brien J C, Cai C J, et al. Generative Agents: Interactive Simulacra of Human Behavior[EB/OL]. 2023. arXiv:2304.03442v2.

[13] Packer C, Wooders S, Lin K, et al. MemGPT: Towards LLMs as Operating Systems[EB/OL]. 2023. arXiv:2310.08560v2.

[14] Hong S, Zhuge M, Chen J, et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework[C]//International Conference on Learning Representations. 2024. arXiv:2308.00352v7.

[15] Baek J, Jauhar S K, Cucerzan S, et al. ResearchAgent: Iterative Research Idea Generation over Scientific Literature with Large Language Models[C]//Proceedings of NAACL: Human Language Technologies. 2025: 6709–6738. DOI:10.18653/v1/2025.naacl-long.342.

[16] Ghafarollahi A, Buehler M J. SciAgents: Automating scientific discovery through multi-agent intelligent graph reasoning[EB/OL]. 2024. arXiv:2409.05556v1.

[17] Schmidgall S, Su Y, Wang Z, et al. Agent Laboratory: Using LLM Agents as Research Assistants[EB/OL]. 2025. arXiv:2501.04227v2.

[18] Gottweis J, Weng W H, Daryin A, et al. Towards an AI co-scientist[EB/OL]. 2025. arXiv:2502.18864v1.

[19] Boiko D A, MacKnight R, Kline B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624: 570–578. DOI:10.1038/s41586-023-06792-0.

[20] Edge D, Trinh H, Cheng N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization[EB/OL]. 2024. arXiv:2404.16130v2.

[21] Sarthi P, Abdullah S, Tuli A, et al. RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval[C]//International Conference on Learning Representations. 2024. arXiv:2401.18059v1.

[22] Asai A, Wu Z, Wang Y, et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[EB/OL]. 2023. arXiv:2310.11511v1.

[23] Liu N F, Lin K, Hewitt J, et al. Lost in the Middle: How Language Models Use Long Contexts[EB/OL]. 2023. arXiv:2307.03172v3.

[24] Du Y, Li S, Torralba A, et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate[EB/OL]. 2023. arXiv:2305.14325v1.

[25] Huang J, Chen X, Mishra S, et al. Large Language Models Cannot Self-Correct Reasoning Yet[EB/OL]. 2023. arXiv:2310.01798v2.

[26] Yamada Y, Lange R T, Lu C, et al. The AI Scientist-v2: Workshop-Level Automated Scientific Discovery via Agentic Tree Search[EB/OL]. 2025. arXiv:2504.08066v1.

[27] Skarlinski M D, Cox S, Laurent J M, et al. Language agents achieve superhuman synthesis of scientific knowledge[EB/OL]. 2024. arXiv:2409.13740v2.

[28] Lu C, Lu C, Lange R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. 2024. arXiv:2408.06292v3.

[29] Bran A M, Cox S, Schilter O, et al. Augmenting large language models with chemistry tools[J]. Nature Machine Intelligence, 2024, 6: 525–535. DOI:10.1038/s42256-024-00832-8.

[30] Chen Z, Chen S, Ning Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C]//International Conference on Learning Representations. 2025. arXiv:2410.05080v3.

[31] Wijk H, Lin T, Becker J, et al. RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts[EB/OL]. 2024. arXiv:2411.15114v2.

[32] Cemri M, Pan M Z, Yang S, et al. Why Do Multi-Agent LLM Systems Fail?[EB/OL]. 2025. arXiv:2503.13657v2.

[33] Kassis T, Agarwal V, He Y, et al. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents[EB/OL]. 2026. DOI:10.48550/arXiv.2609.00065.

资料与工具说明 资料检索、写作修订及图表制作使用 Codex 辅助，并参考 Scientific Agent Skills 流程[33]。本文未独立复现实验；定量图据原文重绘，转载图注明许可。本文为待作者核定的课程综述修订稿。