面向科研任务的多智能体系统综述

知识、记忆与协作的机制及证据边界

蒋佳豪　学号：22671064
浙江大学伊利诺伊大学厄巴纳香槟校区联合学院

摘　要　大语言模型与检索、程序执行及实验平台的结合，使科研辅助由单轮问答扩展到跨阶段的研究流程。多智能体系统进一步通过角色分工与交互协调组织这些能力，但流程自动化程度与科学结论可信度并不等价。本文围绕知识获取、状态延续和协作检验，对 15 项代表性原始研究进行叙述性综述。首先从知识、状态和控制三个层面建立方法分类，解释图检索、分层记忆与工具反馈的作用及相互依赖；随后比较计算实验、假设生成和实体实验三类科研系统，并以原始论文表格重绘结果，分析任务差异与审计材料对评价结论的影响。比较表明，信息覆盖、过程连贯与角色一致分别对应不同目标，不能作为事实正确、实验有效或科学发现的替代指标。本文据此提出以断言及其证据关系组织科研状态，将独立观察、失败记录和条件化验收贯穿协作流程，并讨论固定资源预算下的对照设计、创新性与可检验性的张力及人工参与的合理位置。未来系统的关键进展应体现为可核验研究产出的改善，而不仅是代理规模或论文生成速度的提升。

关键词　多智能体系统；自动科研；检索增强生成；长期记忆；证据核验

Abstract　Large language models can connect literature retrieval, code execution and laboratory tools into extended research workflows. Multi-agent systems organize these capabilities through role assignment and communication, yet workflow completion alone does not establish scientific validity. This narrative review examines 15 representative primary studies through three functional layers: knowledge access, persistent research state and collaborative control. It compares computational research assistants, hypothesis-generation systems and experimentally grounded laboratories. Figures redrawn from published tables illustrate task-dependent performance and the value of process artifacts for auditing. The synthesis distinguishes information coverage from factual support, coherent memory from valid evidence, and agent agreement from independent verification. It argues for claim-level provenance, revisable research records and conditional acceptance criteria, with evaluation controlling computational resources and human assistance. Progress should be assessed by verifiable research outcomes rather than agent count or manuscript throughput.

Keywords　multi-agent systems; automated research; retrieval-augmented generation; long-term memory; evidence verification

1　引言

科研工作的困难既在于提出有价值的问题，也在于使结论经受证据检验。以文献综述为例，找到相关论文只是起点，研究者还需要辨别实验条件、识别相互矛盾的结果，并判断局部发现能否支持一般命题；在计算实验中，程序顺利运行之后，仍要排除数据泄漏、不公平对照和选择性报告。因此，能够生成答案与能够参与研究之间，存在由一系列方法学约束构成的距离。

大语言模型（large language model，LLM）提供了新的技术路径。检索增强生成（retrieval-augmented generation，RAG）将外部文档接入生成过程[1]，ReAct 把推理与工具行动交替组织[2]，AutoGen 进一步将模型、工具和人的输入放入可编程的代理交互[3]。在此基础上，The AI Scientist 和 Agent Laboratory 将文献、代码、实验与论文撰写连接为较长的工作流[4, 5]。人不再需要逐次发出每个细小指令，系统可以根据当前结果选择后续动作。不过，研究链条越长，错误也越可能跨阶段传播，最终以结构完整的报告形式出现。

课堂关于知识增强、长期记忆和可信科研的讨论，恰好触及这一矛盾。知识组织决定系统接

触什么材料，记忆机制决定后续阶段保留什么，协作规则决定不同主体怎样解释材料并接受彼此的交付。若仅按框架名称罗列方法，就容易忽略这些机制之间的依赖。本文因此将核心问题设为：**多智能体系统如何把可用的信息和协作过程，转化为可被第三方检验的科研结论？**

本文讨论基于 LLM、能够选择工具或后续动作的科研智能体。“多智能体”指其中存在可区分的任务主体与通信、协调关系，不要求各主体使用不同基础模型。范围不包括全部多智能体强化学习和群体机器人，也不把蛋白质预测等专用模型本身等同于科研代理。专用模型在本文中主要作为可以被代理调用、仍需独立评价的工具。

1.1 文献范围与组织方式

本文采用问题导向的叙述性综述。资料核对截至 2026 年 11 月 9 日，围绕检索增强、上下文利用、代理记忆、协作框架和自动科研评价，通过题名、关键词检索及参考文献追踪，选取 2020 至 2025 年形成的 15 项代表性原始研究。纳入依据是与上述问题直接相关、全文可获取，且具有可分析的机制、案例或评价过程。基础机制、科研应用与失败研究分别保留，避免只以成功案例构造结论。同一工作的预印本和期刊稿不作为两项独立研究重复计数：Virtual Lab 与 Coscientist 采用期刊版本，其余按文末列出的固定版本讨论。本文没有进行全数据库穷尽检索、双人独立筛选或元分析，不能视为该领域的完整统计画像。

全文依次讨论功能分类、知识与记忆机制、协作组织、科研案例及评价方法，最后给出本文理解。图表区分三种性质：机制图是对文献的分析归纳，数值图由原始论文表格重绘，设计建议属于本文讨论。这一区分有助于避免把综述中的解释性框架误当成新的实验发现。

2 分析框架：知识、状态与控制

2.1 从角色名称转向功能约束

“规划者”“研究者”“审稿者”等身份可以帮助分工，却不足以说明系统如何工作。两个名称不同的代理，若接收相同材料、调用相同模型并按相同标准评分，可能只是对同一过程的重复采样；一个代理也可以分阶段完成检索、执行与检查。因此，分类的基本单位应当是功能及其约束，而非对话中的人物数量。

本文将相关机制划分为三个相互耦合的层面，见图1。**知识层**管理外部论文、数据和工具文档，关注检索与来源；**状态层**管理本项目的假设、观察、计划与失败，关注持续性和可修正性；**控制层**决定动作、通信、交接和停止，关注协调与验收。科研结论横跨三层：它既需要外部依据，也需要当前实验状态，还需要明确的接受规则。这一划分是分析视角，并非要求实际系统部署三个独立模块。

2.2 科研流程与科学证据的区别

科研代理同时面对两类成功条件。第一类是操作成功，例如找到论文、代码无报错、实验生成了指标；第二类是认识上的成功，例如引用支持论断、实验排除了主要替代解释、结果能够被独立重建。操作成功通常容易记录，认识上的成功则依赖问题本身。如果奖励只针对论文完整性、单次测试成绩或审稿模型评分，系统可能优化这些替代目标，却没有相应改善研究的可信性。

因此，“闭环”需要具体说明。在仅由语言模型生成、评论、再修改文本的闭环中，反馈仍主要来自语言判断；加入代码测试后，能够检查的是某些程序行为；进一步引入合适的实验观察，才可能检验相应的经验命题。闭环是否有价值，取决于反馈测到了什么，而不是箭头是否返回起点。

3 知识增强与记忆：从可访问到可修正

3.1 RAG 的检索对象与证据支持

RAG 将参数化生成与非参数化文档检索结合，原始工作比较了不同的文档条件化方式[1]。其基本思想可概括为对候选文档的条件生成进行加权：

$$p(y \mid x) \approx \sum_{z \in \mathcal{R}(x)} p(z \mid x)\, p(y \mid x, z), \qquad (1)$$

其中 x 为问题，z 为检索文档，y 为输出，$\mathcal{R}(x)$ 为候选集合。该式说明检索与生成的联系，不代表所有 RAG 实现都显式计算这一边缘概率。检索使外部资料能够影响输出，也使更新知识不必完全依赖重新训练模型。

但相似性检索回答的是“这段材料是否相关”，科研引用要求的却是“材料是否支持当前断言”。例如，某方法在给定数据集上优于一个基线，不等于它在所有任务上都有效；讨论中提出的可能解释，也不等于实验确认的机制。如果生成阶段抹去限定，即使参考文献真实存在，仍会产生证据错配。科研用途的检索单元因而不宜仅有正文，还应保留实验对象、比较条件、证据类型与定位

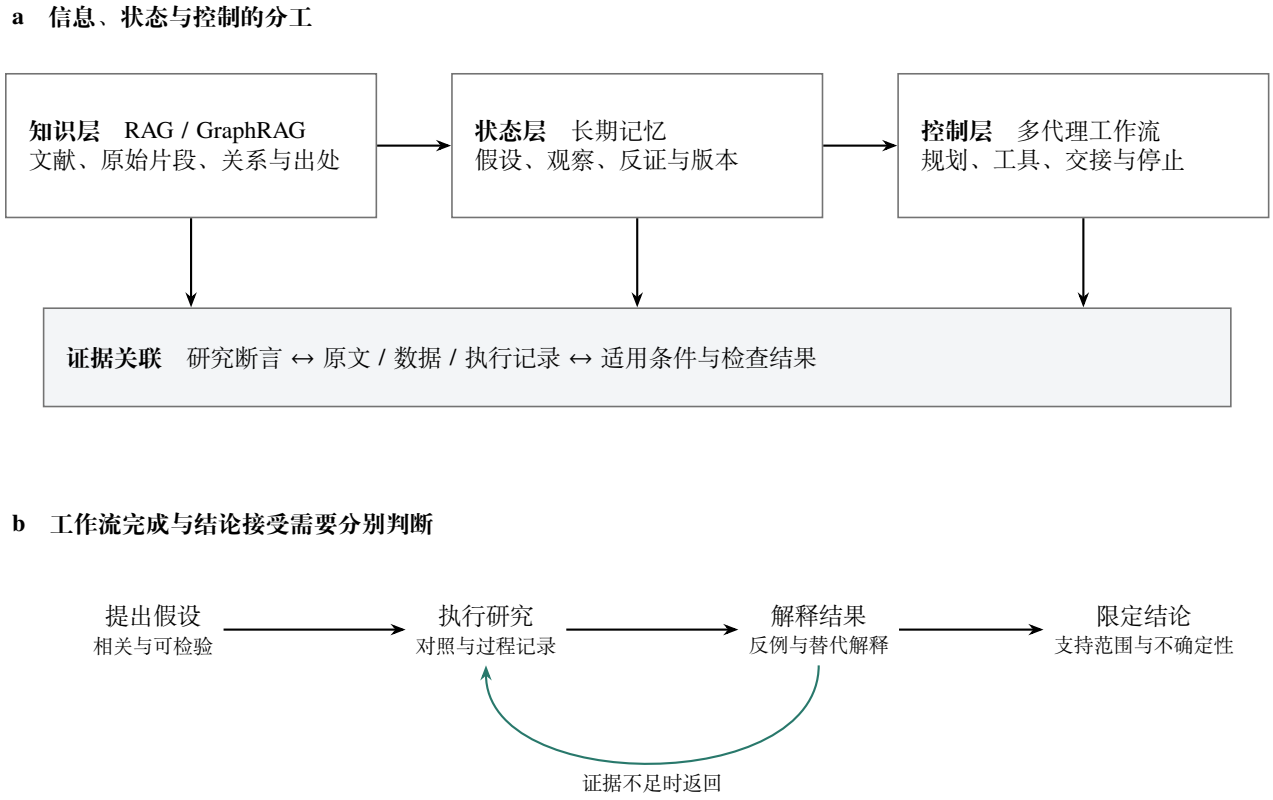


图 1 面向科研任务的功能分析框架。上部综合 RAG、分层记忆与代理交互机制[1, 3, 6]；下部为本文提出的解释与验收关系。箭头表示信息或控制联系，不表示测得的因果增益。

信息。

实践中，可以把生成拆成“提出待支持断言”和“核对支持关系”两个动作。后者需要允许不支持、部分支持和证据冲突，不能迫使每次检索都为既定结论寻找背书。这种设计不保证理解一定正确，却使错误更容易暴露，也便于人工复核。关键变化是将出处看成可以检查的关系，而非文末增加的装饰。

3.2 GraphRAG 与长上下文的适用条件

向量检索适于定位局部片段，但领域性问题往往要求组织分散的信息。GraphRAG 抽取实体和关系，建立图社区及不同层次的社区摘要，再通过全局查询过程聚合回答[7]。它改变的是证据组织与访问方式：可以先看主题结构，再向原文追索细节，而不必把若干局部片段的拼接当成对整个领域的概括。

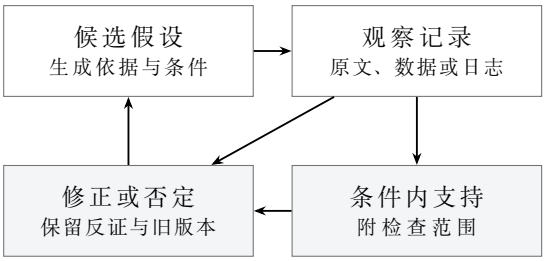
然而，图结构并不天然忠实于原文。实体消歧决定哪些对象被合并，关系抽取决定哪些依赖得以保留，社区摘要又会压缩实验条件、否定信息和少数观点。任一环节的误差都可能在后续总结中放大。因此，图适合提供主题地图，却不宜成为无法回溯的唯一知识表示。关于数值、机制和争议的关键断言，仍应返回对应原文或数据。

GraphRAG 原文针对全局理解问题，比较答案全面性、多样性等维度，这些指标与逐条事实准确率并不相同[7]。全面的回答可以包含更多正确信息，也可能包含更多未经充分支持的信息。“图检索更好”必须附带查询类型和评价标准，不能直接转化为科研结论更可靠的普遍判断。

另一条路线是扩大上下文窗口，直接把较多文献交给模型。Lost in the Middle 通过改变相关信息的位置，说明所测模型对长输入的利用并不均匀[8]。其直接对象是特定时期的模型和任务，不能替代对新模型的测试；它揭示的设计问题仍值得保留：信息进入窗口、被注意到和被正确解释，是三个不同阶段。长上下文与检索因此并非互斥路线。前者减少部分切分损失，后者提供选择、定位与再次核查的能力，二者是否结合应由任务规模和证据密度决定。

3.3 长期记忆究竟保存什么

知识库描述外部研究，任务记忆描述当前项目的经历。Generative Agents 将事件记录、检索、反思与规划结合，展示长期经历如何支持较连贯的代理行为[9]。记忆检索综合考虑相关性、时间和重要性，其启发是：过去的信息不必全部重复输入，系统可以按当前任务选择有用经历。但原



状态可以改变；原始证据与改变理由持续可追溯。

图 2 本文提出的科研记忆状态示意。借鉴记忆检索与分层存储思想[6, 9]，加入断言状态和修正关系；这是设计建议，并非原文已验证的架构。

工作主要研究社会行为的可信感，没有证明反思所得命题具有科学真实性。用于科研时，需要重新设计“重要性”和“有用性”的含义。

MemGPT 借鉴存储层级，区分有限的当前上下文与外部存储，通过显式操作调入或移出内容[6]。这一思路使记忆调度成为系统行为的一部分，适合延续长任务。不过，能够保存和调用记录，只能说明它没有丢失，不能说明它值得相信。科研记忆至少需要区别原始观察、推断、计划和已否定判断。否则，早期推测可能在反复摘要之后失去语气与来源，成为后续代理眼中的“已知事实”。

本文据此把科研记忆理解为可修订的研究记录，状态示意见图2。记录应关联来源、适用条件和当前状态；新证据可以改变状态，但不应抹去先前依据及修正过程。例如，实验未达到预期时，应保留配置、失败表现和可能原因，而非只记住最终成功的运行，因为失败有助于区分稳健规律与偶然调参结果。

3.4 知识与记忆的耦合及代价

知识和记忆都可能使用向量、图或文档存储，区别主要在来源与用途。若把外部论文、代理摘要、实验输出和旧假设存入无类型区分的库，系统可能把自身历史猜测误当成独立外部证据。由此产生循环支持：先生成判断，再写入记忆，后续检索又用它证明原判断。避免这一问题，需要读取时保留来源身份，并区分原始证据和派生摘要。

来源追踪和版本记录也会增加管理负担。过细的记录挤占上下文与检索预算，过度压缩则会损失决定结论边界的条件。合理目标不是保存全部对话，而是保留足以重建关键判断的材料。常规工具说明可以缓存简短摘要，研究方向变更和异常结果则需更完整依据。按风险分配记忆精度，比单纯追求记忆条目数量更接近科研需求。

4 协作组织：从行动反馈到多主体协调

4.1 ReAct 说明了什么

ReAct 根据当前信息产生推理或行动，通过环境返回的观察调整后续步骤[2]。它通常属于单代理机制，却是理解多代理科研流程的基础：检索结果、执行报错和测试输出提供新的观察，使系统不必仅在内部文本中反复推测。反馈价值取决于观察与问题的关系。程序报错可以揭示实现问题，通过测试可以支持部分程序属性，但不能直接验证研究问题的价值。

图3重绘原文的同一模型提示实验。在 HotpotQA 上，ReAct 严格匹配率为 27.4%，低于 CoT 的 29.4%；在 FEVER 上，ReAct 准确率为 60.9%，高于 CoT 的 56.3%。推理、检索与自一致性采样的组合在两任务中的表现也不同。外部行动的作用因而依赖任务：事实核查可以直接受益于证据查询，多跳问答还受检索路径与答案综合影响。这些结果不支持“有工具就一定优于纯推理”，也不能被当成多代理协作的效果证据。

4.2 分工、通信结构与交接约束

AutoGen 通过可对话代理与可编程交互，将 LLM、工具和人纳入统一协作方式[3]。科研分工可以体现为检索与核对、实现与测试、假设提出与反例搜索。其收益来源可能不同：并行处理缩短等待，工具专长降低操作难度，独立检查发现遗漏；这些收益不应全部归入抽象的“群体智能”。

协作拓扑也会影响结果。串行流水线容易规定交付顺序，但早期错误可能逐层传递；中心调度便于整合，却依赖调度者正确理解任务；自由讨论可以扩大探索范围，也容易形成无效轮转和过早共识。若 n 个代理每轮均向其他所有代理发送一条消息，T 轮的有向消息数为 $Tn(n-1)$。这一计数仅适用于该通信假设，实际成本还取决于消息长度和工具执行内容。它提示：角色增加时，信息协调可能比子任务执行更快地消耗资源。

代理应交付明确对象，而非只说“任务已完成”。检索者提供原文及限定，执行者提供配置与结果，核对者指出检查对象、标准和未解决问题。验收既可以通过，也应允许带条件通过、退回和中止。当后续代理不能重建前序判断时，继续对话很可能只增加文本长度，未增加研究信息。

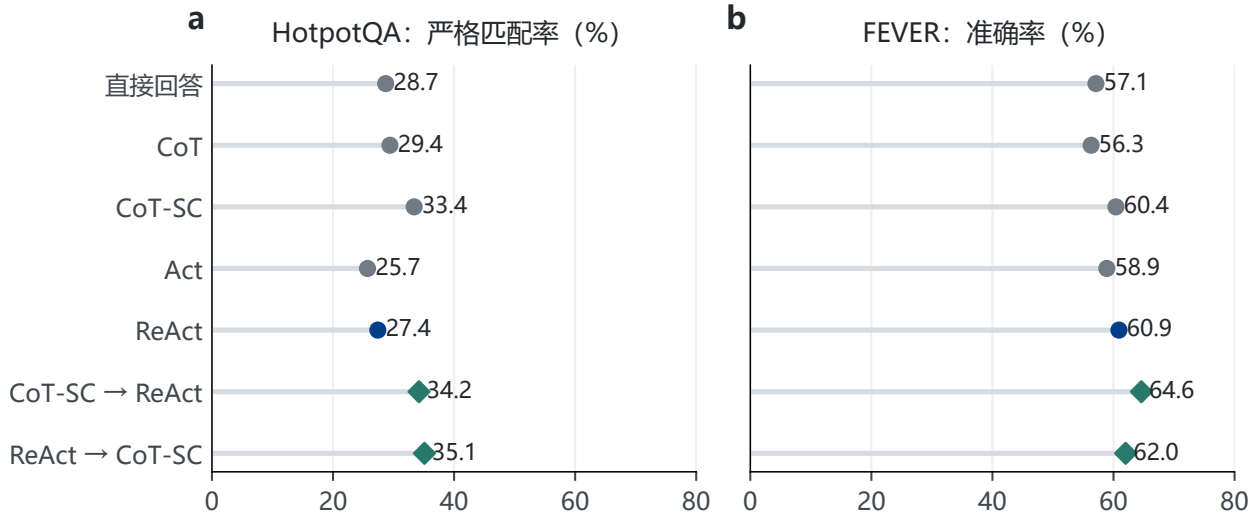


图 3 ReAct 收益的任务依赖性。数值重绘自文献[2] 表 1（PDF 第 5 页），基础模型为 PaLM-540B。左为 HotpotQA 严格匹配率，右为 FEVER 准确率；跨面板指标不同。CoT-SC 使用 21 条推理轨迹，组合方法涉及工具调用，各条件并非相同推理成本的对照。展示原文点估计，未补造误差条；不纳入原表的有监督最优方法行。

4.3 多角色一致为何不是独立证据

同一模型设成不同角色，并不自动获得独立判断。共享训练偏差、相同上下文、相同检索错误及先发意见影响，都可能使多个代理重复同一错误。只有当角色带来新观察、约束或检验途径时，协作才具有实质核验增量。让执行者重新计算、让检查者获取原始数据，比让多个角色评价措辞是否可信更接近证据检查。

一个简化统计关系可以说明相关判断的局限。假设 n 个判断的方差均为 σ^2，两两相关系数相同且为 ρ，则

$$\mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}\{1 + (n-1)\rho\}. \tag{2}$$

这是等相关假设下平均判断方差的数学说明，不是实际代理相关性的测量，也不直接给出投票正确率。当判断正相关时，增加主体的信息收益弱于独立情形。科研系统需要说明不同角色的证据来源，不能只报告投票人数或赞成比例。

没有外部反馈的自我修正也面临类似问题。Huang 等在所测推理任务上发现，内在自我纠错不能稳定改善结果，甚至可能改变原先正确的答案[10]。这不是对所有反思方法的否定，而是提醒：提示语中的“检查”不等于系统拥有可靠的错误判据。多代理审核若仍仅依赖同类语言判断，也需要接受相同追问。

5 自动科研案例：自动化覆盖与验证深度

5.1 计算实验：The AI Scientist 与 Agent Laboratory

The AI Scientist 将创意生成、代码修改、实验运行、图表绘制、论文撰写与模拟评审连接起来，在扩散建模、语言建模和学习动力学等机器学习方向展示工作流[4]。其意义在于把分散的辅助能力组成较完整的研究过程，允许一个想法继续进入实现与检验阶段。但“自动生成论文”与“完成开放式科学发现”仍需区分：研究模板、工具、预设任务和评价方式限定了系统能够探索的空间。尤其是自动评审分数超过某个阈值，不等于论文通过了独立学术评审，也不意味着结论得到重复验证。

Agent Laboratory 更明确地以帮助人类落实研究想法为目标，通过文献阅读、实验和报告等阶段组织代理，并允许不同程度的人为反馈[5]。这使“是否全自动”不再是唯一指标：当问题需要领域判断时，保留交互可能比让系统独立走完整条流程更有价值。不过，人的介入同时改变输入信息、任务约束与修改机会，评价需要记录其位置和程度。

该论文报告了自动与人工评价的差异：相应比较中的总体自动评分为 6.1/10，人工评分为 3.8/10[5]。两者反映具体设置中的评价差距，不能解释为所有自动评审都有相同偏差。它们说明，报告语言与结构得到较高评价时，研究质量仍可能不足。同一论文的人机协同实验也出现不同维度的取舍，不能简化成“只要人工参与，所有结果

表 1 代表性机制的比较。比较单位为功能与约束，不构成跨论文性能排序。

机制	主要处理对象	适合解决的问题	尚需单独解决的问题
RAG[1]	外部文档与相关段落	降低对参数记忆的依赖，支持材料更新	检索是否完整，段落是否支持断言
GraphRAG[7]	实体关系、社区与摘要	跨文档主题组织和全局概括	抽取误差、条件丢失和回溯原文
经历记忆[9]	事件记录、反思与计划	在多轮任务中延续相关经历	行为连贯与科学真实性的目标差异
分层记忆[6]	当前上下文与外部存储	在有限窗口中管理长期状态	记录真实性、冲突处理与版本修订
ReAct[2]	推理、行动和环境观察	将外部反馈引入后续动作	检索路径、反馈解释与任务适配
代理交互[3]	角色、消息、工具和人	组织分工及可编程工作流	交接契约、终止条件和独立验收

都会改善”。

两类系统共同展示了计算实验易于自动化的原因：代码、数据和指标能够直接进入工具闭环。其共同局限是容易把可计算的成绩当成研究意义。能否提出有效对照、合理选择任务、完整报告失败，依然决定结果的解释空间。比较此类系统时应分别报告流程完成率、执行成功率和结论质量，避免以其中一项代替其余两项。

5.2 假设生成：AI co-scientist 的搜索与排序

AI co-scientist 围绕人给定的目标，组织生成、反思、排序、演化等代理，通过候选假设间的讨论与锦标赛式比较，迭代形成研究建议[11]。与按固定顺序执行一次研究相比，这类方法把更多资源用于候选空间探索，使想法可以被修改、组合或淘汰。核心不仅是角色数量，还在于候选怎样产生、评价如何影响下一轮，以及外部目标如何约束搜索。

这类机制存在代理目标与科学目标之间的距离。锦标赛排名衡量相对于其他候选的评价优势，不是命题为真的概率；如果候选与评价者共享知识盲区，排名可以持续提高，真实研究价值却改善有限。容易表述、容易与已有文献一致的假设，可能在语言评价中占优，但不一定比更冒险、更难解释的假设更有科学价值。

该研究在药物再利用、肝纤维化靶点和细菌基因转移机制等方向报告验证案例[11]。这些案例提供了超出文本评分的证据，但应保留性质差异：体外细胞或类器官结果属于特定条件下的支持，不能扩展为临床有效；重现当时尚未公开的实验机制，与从未知问题独立完成全部发现过程也不相同。将这些结果混写成“系统已证明能够普遍自主发现”，会丢掉最值得分析的证据边界。

5.3 跨学科设计：Virtual Lab 的计算与实验衔接

Virtual Lab 采用负责人代理与专业代理的研究会议形式，由人类提供高层反馈，把不同知识和工具组织到纳米抗体设计问题中[12]。其计算流程整合蛋白质语言模型 ESM、结构预测工具 AlphaFold-Multimer 与 Rosetta，选择 92 个候选进行实体实验。这里，LLM 主要承担讨论、规划和工具整合，具体序列或结构评价依赖专用工具，实验验证由研究人员完成。将所有结果归于 LLM 自身的生物学推理，会掩盖这些关键贡献。

该论文展示了预测指标与实际功能之间的距离。92 个候选中，78 个的 AlphaFold 界面局部置信度指标高于相应亲本，60 个具有更优的 Rosetta 结合能；这些计算结果并没有使所有候选获得理想结合表现[12]。实验中，不同亲本系列的效果差异明显，论文最终重点分析两个对较新变体具有有前景结合表现的候选。计算分数提高、可溶性表达和特定抗原结合是不同层面的结果，不能相互代替。

该案例的证据价值不在于给出通用的“发现成功率”，而在于连接了代理提出的计算流程、候选筛选和后续测量。92 个设计与两个重点候选也不能直接组成未经定义的成功率：“成功”需要预先说明针对哪种变体、何种结合阈值及什么对照。避免随意计算这一比值，比为图表增加醒目的百分数更符合证据含义。

5.4 实验执行：Coscientist 的工具链与反馈

Coscientist 结合检索、文档查阅、代码执行和实验自动化，展示了从自然语言要求到化学实验设计与执行的路径[13]。其代表过程包括根据装置文档修正接口调用，并用分析仪器结果检查产物。与纯文本审核相比，这类观察具有不同来源，能够直接约束关于实验执行和产物的部分判断。

但实体工具接入不意味着流程完全自主。论

文说明部分装置操作仍由人工完成，可探索的资源与反应空间也受到设置限制[13]。成功执行特定反应首先支持该场景下的工具整合能力，不能推断开放实验室中的通用发现能力。对于高成本或不可逆操作，系统还需要纳入设备约束、异常中止和人类决定；这些约束本身也是科研工作的一部分。

5.5 案例综合：自主程度与证据深度是两个维度

表2显示，系统间最有意义的差异并非谁覆盖的阶段最多，而是谁在什么环节引入了何种检验。计算科研助手便于扩展运行次数，却需重点检查实验方法；假设系统扩大候选范围，却需更强筛选和外部验证；实体实验系统接触真实观察，但吞吐、资源和安全约束更明显。不能用“更自动”推导“更可信”，也不能因为有实体实验就忽略设计本身。

这改变了对人的角色的理解。在人机协作中，人可能规定研究价值、提供关键约束或操作仪器，不只是事后阅读报告。这些贡献未被记录时，自动化收益会被高估；若把所有人工介入都当成失败，也会错过以较低成本获得高质量研究的路径。评价应说明系统在多大帮助下解决了什么问题，而非用“自主”标签覆盖差异。

6 失败机制与可信性评价

6.1 失败沿研究链条怎样传播

MAST 研究将多代理失败归纳为规范与系统设计、代理间失配和任务核验等类别[14]。过程视角比只统计最终错误更有解释力：一个代理可以正确执行错误目标，也可以把未经检查的内容交给下一角色，最后由另一个代理依据不完整材料宣布成功。单独改善某个模型的回答能力，未必能修复这些组织性问题。

科研失败至少会在四种转换处积累。外部文献转为结构化知识时，可能丢失否定与条件；观察转为记忆摘要时，可能混入解释；计划转为代码与设备指令时，可能发生目标偏移；结果转为论文结论时，可能放大优势、遗漏失败。这些转换既是自动化接口，也是需要验收的边界。只在论文写完后检查语言，通常难以重建前面发生了什么。

Luo 等针对 AI 科研系统设计受控任务，分析基准选择偏差、数据泄漏、指标误用和事后选择偏差[15]。其价值在于把“论文看上去是否合理”转化为可检查的问题。不过，风险不能被写成所有缺陷都在所有系统中自然出现：该文部分审计阳性样本由作者注入缺陷构造，真实运行中不同缺陷的出现情况并不相同。受控审计能检验检查材料的作用，却不能直接给出部署环境中的缺陷流行率。

6.2 为什么需要论文之外的研究材料

图4重绘 Luo 等的审计实验。在每类 20 个、阳性与阴性均衡的样本上，审计模型仅看论文时的准确率接近随机水平，加入轨迹日志和代码后，五类问题的识别准确率均提高[15]。总体准确率由 55% 提高到 82%，但该点估计依赖样本组成和审计模型，不意味着真实科研审计能够达到同样数值。

这组结果提供了比“增加审稿代理”更具体的方向：先给检查者足够的可核查对象。仅看最终指标，难判断测试集是否参与调参；代码与日志可以暴露数据访问过程。仅看最佳实验，难知道是否省略大量失败；完整运行记录可以显示选择路径。但记录更全面也不等于容易理解。长日志需要索引、时间顺序和关键事件关联，不应由生成论文的同一摘要完全替代原始过程，否则会失去独立检查所需的细节。

6.3 公平比较必须控制什么

评价多代理收益时，合理对照不只是“一个代理”与“多个代理”。应尽可能固定基础模型、资料、工具权限、总调用预算与人工帮助，让单代理获得相应的推理、检索和重试机会。如果多代理同时获得更多样本、更长上下文和更多运行时间，提升可以说明整个系统有效，却不能单独证明角色分工是收益来源。

可以使用功能消融区分贡献：移除独立证据核对但保留角色数，观察收益是否消失；保留工具和预算但合并角色，检查通信是否必要；关闭记忆的来源和状态区分，检查长期任务是否更容易重复错误。这些是本文建议的研究设计，并非本文已经运行的实验。消融还需说明代偿规则，例如删除角色后是否将其预算交给其他角色，因为不同处理会改变实验实际回答的问题。

除平均成绩，还应保留完成率、失败类型和单次任务分布。若只对完成的任务报告质量，就会隐藏系统经常中断的成本；若只展示最佳运行，无法判断稳定性。科研辅助尤其需要记录人的修改与系统放弃的理由，因为能够识别证据不足并停止，可能比坚持生成确定结论更适合研究。

表 2 五种代表性科研系统的证据比较。“验证”针对各自研究问题，不表示统一证据等级或性能排名。

系统	自动化的主要对象	原文提供的关键证据	解读时的主要边界
The AI Scientist[4]	从想法、计算实验到论文和模拟评审	多个机器学习方向的端到端示例与自动评审评价	模拟评分不是独立录用；模板与任务限制探索范围
Agent Laboratory[5]	在人的研究想法上组织文献、实验和报告	后端比较、人工评价及不同参与模式	人工与自动评分有差距；人工帮助需计入条件
AI co-scientist[11]	生成、比较并迭代研究假设	自动评价、专家反馈及部分生物医学实验案例	候选排名不是真值概率；验证案例性质不同
Virtual Lab[12]	跨学科讨论与计算设计流程	92 个设计候选的实验表征及重点候选分析	专用模型与人承担关键环节；预测不等于功能
Coscientist[13]	工具文档、协议设计与设备调用	装置执行、错误修正及产物分析	装置和资源受限，部分物理操作仍依赖人

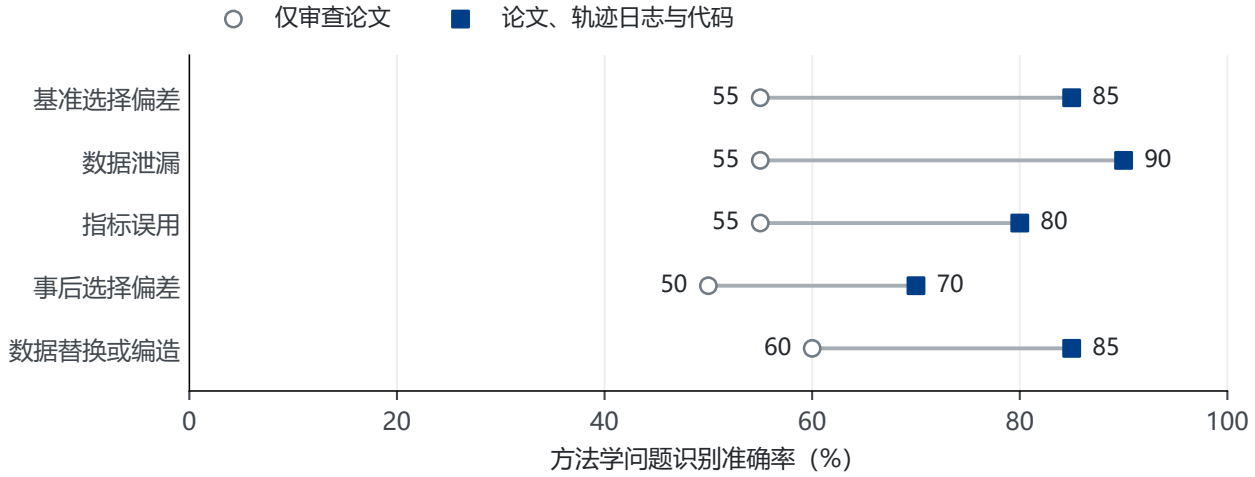


图 4 研究过程材料对方法学问题识别的影响。重绘自文献[15] 第 6.2 节与表 11（固定预印本 v2，PDF 第 16–18 页）。每类 20 例，含 10 例阳性和 10 例阴性；部分问题由原作者受控注入，不代表自然发生率。审计者为 gemini-2.5-flash-preview-05-20。图为准确率点估计，没有重复运行分布，未补造误差条。两条件同时改变日志与代码可用性，不能分别归因于某一种材料。

表 3 本文建议的评价对象与检查内容。各维度分别报告，不合成为主观总分。

评价对象	需要检查的内容
断言与来源	原文是否支持、条件是否保留、冲突是否呈现
实验有效性	数据划分、对照公平性、指标定义与重复运行
过程可追溯	配置、日志、失败尝试和状态修订能否关联
协作增量	相同资源下相对单代理及功能消融的变化
参与与成本	人工输入、修改程度、调用和工具资源
失败恢复	能否发现异常、退回修正，并在证据不足时停止

6.4 从单一总分转向有条件的证据报告

表3将对象分开，因为评价维度可能不一致。系统可以较快完成流程，却产生较多引用错配；也可能需要较多交互，却留下更完整的复现材料。若未经说明就合成为总分，权重选择会掩盖这些取舍。更有解释力的报告应说明：在何种任务、资源和参与程度下，改善了哪些方面，又牺牲了什么。

“创新性”也不宜只由语言模型判断与已有文字的差异。新颖表述可能缺乏可行性，复现既有结果却可能对验证工具链很有价值。开放研究需要分别考察已有文献之外的贡献、实验可检验性和结果支持度。三个问题相互关联，但不应由同一个缺少外部依据的分数一次回答。

7 讨论与展望

7.1 以断言及其证据关系组织科研状态

综合上述研究，本文倾向于将科研系统的持久对象设为“带条件的断言”，而非不断扩充的聊天记录。重要断言应关联文献或实验依据、适用范围、反对证据和当前状态。知识图谱连接概念，任务记忆记录判断怎样变化，代理工作流则围绕证据缺口分配任务。这样，三层机制能够围绕共

同研究对象协作，而非各自积累更多文本。

这种组织有助于定位返工范围。若数据处理发现错误，应识别受影响的指标和结论，而非机械地重跑所有阶段；若新文献只改变某个适用条件，也不应丢弃全部旧观察。未来记忆系统值得关注的因而不仅是检索召回，还包括依赖追踪、反证写入和局部修订。难点在于关系本身也可能由模型抽取，仍需抽样检查及高影响断言的人工复核。

7.2 在探索与核验之间分配资源

多代理能产生更多候选，但验证能力不会自动增长。当假设生成远快于实验检查，候选数量会成为负担：研究者需花更多时间筛选看似合理却缺少依据的想法。探索预算应与验证预算共同规划，并将可检验性纳入筛选。例如，优先比较能够被现有数据或低成本实验区分的假设，再决定是否投入昂贵验证。

验证也不能只奖励符合共识的候选。若把“与已有文献一致”作为唯一标准，系统容易保守地重组已知结论，难以探索争议问题。较合理的做法是区分：已知事实有无错误，推测是否逻辑连贯，以及需要何种观察才能支持或否定它。对创新的容忍应体现为允许明确标注的假设，而非降低事实陈述的准确要求。

这也回应课堂关于可信与创新之间张力的讨论。可靠性不要求只重复已知答案，而要求证据不足时维持正确的认识状态。“尚未证实但值得检验”是合理研究产出，不能为了让报告完整，就把它提前写成已经得到支持的结论。

7.3 按任务风险选择协作规模与人工位置

并非每个科研问题都需要多代理团队。单项事实核对，一个能够查阅原文并定位依据的代理可能已经足够；需要不同工具和专业知识的长任务，分工更容易产生实质价值。规模应由可分解程度、交接成本和验证方式决定，并通过相同预算下的比较检验，而非预先假定代理越多越好。

人工参与应放在判断价值较高的位置。研究目标是否有意义、对照是否合理、结果是否超出证据，通常比格式整理更需要领域经验。在这些阶段设置检查点，可让人审查有限但关键的对象，同时把重复检索、运行和材料整理交给工具。人与系统的贡献都应可见，才能判断辅助是否真正减轻负担。

未来还需要接近真实科研的长期评价。短任务基准通常有明确答案，研究目标却会随新证据改变，有效产出也可能是失败解释或被排除的假设。评价应覆盖跨阶段状态变化、错误恢复与第三方复查，可行时加入预先保留的任务和独立执行者，降低记住答案与共享错误假设的影响。这类评价成本较高，却比持续增加角色名称更能说明系统是否获得新的科研能力。

7.4 本文局限

本文强调信息与证据，未全面讨论训练式多代理优化、经济激励及大规模协作基础设施。所选文献的任务、模型、工具与人工参与不同，不能进行合并效应估计。两幅数值图说明评价条件怎样影响解释，均来自论文内部比较，未提供跨系统优劣的总体证据，也未重新运行原实验。部分结果来自早期模型，升级可能改变具体性能；来源支持、对照有效性与独立检查仍需在新系统中重新落实和验证。

8 结论

面向科研的多智能体系统，将知识获取、长期状态和工具协作整合为连续工作流。RAG 与 GraphRAG 扩展材料获取和组织方式，经历记忆与分层存储延续状态，ReAct 及代理交互使系统能够依据观察调整行动。这些进展分别缓解信息、窗口和协调限制，但没有单一机制能够保证科学结论成立。

案例表明，自动化覆盖与验证深度应分别描述：论文生成、候选排名、计算指标和实体测量提供不同性质的证据，适用范围不能由流畅叙述或角色共识代替。未来值得追求的是围绕断言保持可追溯、可修正的研究状态，用独立观察与明确验收约束协作，并在固定资源与透明人工参与下评价收益。有价值的科研系统应当既能推进值得探索的问题，也能在证据不足时保留分歧、退回和停止。

参考文献

1 Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. 2020. arXiv:2005.11401v4. https://arxiv.org/abs/2005.11401v4.

2 Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[EB/OL]. 2022. arXiv:2210.03629v3. https://arxiv.org/abs/2210.03629v3.

3 Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[EB/OL]. 2023. arXiv:2308.08155v2. https://arxiv.org/abs/2308.08155v2.

4 Lu C, Lu C, Lange R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. 2024. arXiv:2408.06292v3. https://arxiv.org/abs/2408.06292v3.

5 Schmidgall S, Su Y, Wang Z, et al. Agent Laboratory: Using LLM Agents as Research Assistants[EB/OL]. 2025. arXiv:2501.04227v2. https://arxiv.org/abs/2501.04227v2.

6 Packer C, Wooders S, Lin K, et al. MemGPT: Towards LLMs as Operating Systems[EB/OL]. 2023. arXiv:2310.08560v2. https://arxiv.org/abs/2310.08560v2.

7 Edge D, Trinh H, Cheng N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization[EB/OL]. 2024. arXiv:2404.16130v2. https://arxiv.org/abs/2404.16130v2.

8 Liu N F, Lin K, Hewitt J, et al. Lost in the Middle: How Language Models Use Long Contexts[EB/OL]. 2023. arXiv:2307.03172v3. https://arxiv.org/abs/2307.03172v3.

9 Park J S, O'Brien J C, Cai C J, et al. Generative Agents: Interactive Simulacra of Human Behavior[EB/OL]. 2023. arXiv:2304.03442v2. https://arxiv.org/abs/2304.03442v2.

10 Huang J, Chen X, Mishra S, et al. Large Language Models Cannot Self-Correct Reasoning Yet[EB/OL]. 2023. arXiv:2310.01798v2. https://arxiv.org/abs/2310.01798v2.

11 Gottweis J, Weng W H, Daryin A, et al. Towards an AI co-scientist[EB/OL]. 2025. arXiv:2502.18864v1. https://arxiv.org/abs/2502.18864v1.

12 Swanson K, Wu W, Bulaong N L, et al. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies[J]. Nature, 2025, 646: 716–723. https://doi.org/10.1038/s41586-025-09442-9.

13 Boiko D A, MacKnight R, Kline B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624: 570–578. https://doi.org/10.1038/s41586-023-06792-0.

14 Cemri M, Pan M Z, Yang S, et al. Why Do Multi-Agent LLM Systems Fail?[EB/OL]. 2025. arXiv:2503.13657v2. https://arxiv.org/abs/2503.13657v2.

15 Luo Z, Kasirzadeh A, Shah N B. The More You Automate, the Less You See: Hidden Pitfalls of AI Scientist Systems[EB/OL]. 2025. arXiv:2509.08713v2. https://arxiv.org/abs/2509.08713v2.

16 Kassis T, Agarwal V, He Y, et al. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents[EB/OL]. 2026. https://doi.org/10.48550/arXiv.2609.00065.

资料与工具说明 本文为叙述性综述，未重新运行所引系统的实验。资料整理、文字修订与图表代码由 Codex 辅助完成，参考 Scientific Agent Skills 的综述和可视化工作流[16]；该文献仅记录工具来源，不计入 15 项研究的比较。数值图由公开表格重绘，概念图为本文归纳。当前为供作者核阅的课程修订稿。