# 面向科研任务的多智能体系统综述

## 技术脉络、关键方法与可信评价

蒋佳豪　学号：22671064
浙江大学伊利诺伊大学厄巴纳香槟校区联合学院

**摘　要**　科研多智能体系统正将文献阅读、计算实验和实体操作组织成连续工作流，但自动化范围的扩大尚不能直接说明科学判断更可靠。本文围绕知识检索、研究记忆和代理协作梳理代表方法，比较片段检索、层次摘要与关系图的适用问题，分析反思和分层存储的不同作用，并结合文献综合、计算科研与生物化学实验讨论系统产出及其验证方式。ScienceAgentBench 的两组自调试配置中，有效执行率与任务成功率相差约 60 个百分点；过程审计研究也显示，补充日志和代码能够改善缺陷识别。这些现象说明，系统评价需要保留任务、预算和过程材料，不能只依据生成论文或内部评分。本文据此提出，应以研究判断的来源和修订关系组织知识与记忆，以检查能否提供新信息衡量角色分工，并将人的投入纳入协作评价。现有证据支持科研流程的部分自动化，对长期、自主且可复查的研究能力仍需更有针对性的检验。

**关键词**　科研智能体；多智能体协作；检索增强生成；长期记忆；科学发现；可信评价

## A Review of Multi-Agent Systems for Scientific Research: Technical Evolution, Core Methods and Trustworthy Evaluation

**Abstract**　Multi-agent research systems connect literature analysis, computational experiments and physical operations, but wider automation does not by itself establish more reliable scientific judgments. This review compares retrieval structures, reflective and hierarchical memory, and agent coordination, then examines their use in literature synthesis, computational research and biochemical experiments. Published evaluations reveal substantial gaps between valid execution and task success, while access to logs and code changes the detection of methodological defects. These findings motivate comparisons that preserve task conditions, resource budgets and process records. The discussion argues for organizing memory around the sources and revisions of research judgments, assessing whether checking agents contribute additional information, and accounting for human effort. Current evidence supports partial automation of research workflows; sustained and independently inspectable scientific work remains a more demanding objective.

**Keywords**　scientific agents; multi-agent collaboration; retrieval-augmented generation; long-term memory; scientific discovery; trustworthy evaluation

## 1　引言

一项研究从文献阅读推进到实验和结论，需要在多种信息与方法之间作出连续判断。找到一篇相关论文之后，研究者还要判断其中的条件能否迁移到当前问题；完成一次计算之后，也要决定结果是否足以支持原先的解释。这类工作既依赖专业知识，又涉及阅读、实现、比较和修正等连续活动。大语言模型（large language model，LLM）能够在同一语言接口下调用检索、编程与分析工具，使上述活动有可能被纳入相对统一的自动化过程。科研智能体研究正是在这一背景下兴起[1,2]。

检索增强生成（retrieval-augmented generation，RAG）使模型能够利用训练之外的文献[3]；ReAct 让模型依据工具返回的观察继续行动[4]；AutoGen 则提供了组织多个模型实例及其交互的方式[5]。这些方法解决的是不同层次的问题，却常被同时用于一个科研系统。检索者、程序编写者、评审者等角色由此进入研究流程，形成了目前常见的科

研多智能体架构。本文中的“代理”与“智能体”同义；角色是否构成有效分工，取决于其信息和操作上的差异。

随着系统能够承担的研究步骤增多，完成流程仍不足以保证结论得到支持。The AI Scientist 能够组织实验并生成论文[6]，Virtual Lab 将跨学科讨论落实到纳米抗体设计与实验表征[7]，对自动科研的审计却发现，最终报告有时不足以暴露实验过程中的方法学缺陷[8]。三类结果并不冲突：它们分别考察自动化覆盖、特定科学任务和过程可靠性。如果只问系统是否“像科学家”，这些差异很容易被同一个概念掩盖。

已有综述对此给出了不同的整理方式。Zheng 等按工具、分析者和科学家区分自主程度[1]；Wei 等将系统能力与学科应用联系起来[2]；郑逸宁等则细分了工具使用的规划、指令生成与结果处理[9]。本文在这些工作的基础上，围绕三个相互关联的问题展开：系统怎样取得并保存研究依据，多个代理怎样据此协作，现有实验又怎样证明这种协作有用。相比按框架逐项介绍，这一线索更便于解释方法之间的替代关系，也能把课堂涉及的知识图谱、自主记忆和可信科研放在同一个问题下讨论。

本文采用叙述性综述方法，通过题名与关键词检索、引用追踪以及原文核对选取代表工作，资料范围截至 2026 年 11 月 9 日。分析包括基础机制、科研系统与评价研究，不覆盖全部多智能体强化学习或机器人群体研究，也不进行跨论文效应合并。同一项目的不同版本按研究进展引用，例如 The AI Scientist 的早期报告、第二版与期刊稿不作为相互独立的重复验证。下文先厘清研究对象，再讨论知识、记忆与协作方法；随后以科研应用和公开评测检验这些方法的解释力，最后给出本文的判断及尚未解决的问题。

## 2 科研智能体概述

### 2.1 技术演进

科研多智能体并没有一条整齐的代际演进路线。知识检索、工具调用和多主体交互原本处理不同任务，后来才在科研系统中汇合。图1按三个方向整理代表工作的出现时间。RAG 改变的是生成时可以使用的资料，ReAct 改变的是推理与外部行动的交替方式，Toolformer 则研究工具使用能力如何通过训练获得[3,4,10]。这几项工作共同降低了模型接触外部环境的障碍，但本身并不等于科研协作系统。

长期任务还需要保存先前的活动。Reflexion 把任务反馈写成下一次尝试可用的反思[11]；Generative Agents 按相关性、时间和重要程度检索经历[12]；MemGPT 在有限上下文与外部存储之间调度信息[13]。它们分别回答“怎样从一次失败中调整”“哪些经历应当被想起”和“怎样容纳更长历史”，不能仅因都涉及记忆就视为同一种方法。

AutoGen 与 MetaGPT 使任务能够在多个代理之间流转[5,14]。随后，ResearchAgent 和 SciAgents 把文献关系用于研究构思，Agent Laboratory 组织计算实验，AI co-scientist 与 Virtual Lab 把协作延伸到假设筛选和跨学科研究[7,15–18]。值得注意的是，Coscientist 在 2023 年已经连接语言模型与实体装置[19]，而一些更晚的系统仍主要处理文献或代码。技术发展因此表现为多条路线的扩展，不能按发表时间排成从“低级”到“高级”的统一阶梯。

### 2.2 科研智能体的概念界定

本文将能够依据目标、已有观察和保留状态选择下一步行动的模型主体称为智能体。行动可以是查询文献、运行程序、向其他主体提出任务，也可以是结束当前研究。工具调用和多代理协作的区别在于：工具通常执行既定操作，而另一代理还可以根据自己的上下文作出选择。同一系统中往往同时存在这两者。例如，Python 解释器不因被语言模型调用就成为另一个研究者；一个有独立检索任务和判断规则的文献代理则可能构成实质分工。

这一界定影响如何解释实验结果。如果多代理系统比直接提示更好，提升可能来自检索、执行反馈、更多采样或角色分工中的任何一项。只有在这些条件得到控制后，才能进一步讨论主体之间的协作贡献。因此，本文同时纳入若干单代理工具系统作为参照：它们有助于判断某项能力是否真的需要多个主体。这种参照也比单纯统计代理数更接近实际的方法选择。

## 3 知识获取与研究记忆

### 3.1 检索索引结构

科研检索首先遇到的是查询尺度问题。查找某项实验的温度和样本量，需要尽可能接近原文；比较一个领域的研究主题，则需要跨越多篇文献。这两类问题对索引的要求不同，返回更多相似片段并不能自动补足这种差异。

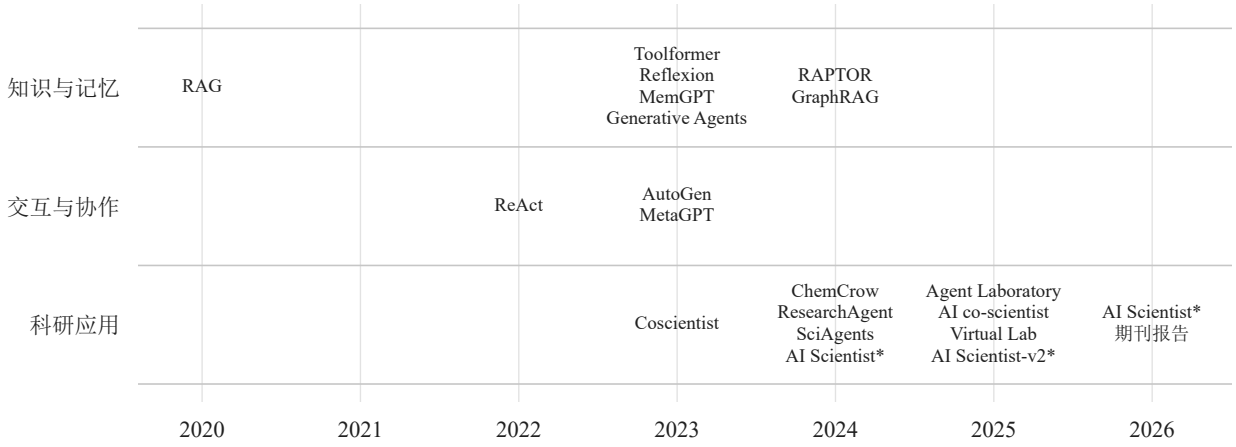



**图 1** 相关技术与科研系统的时间分布。基础方法按首次报告年份定位；星号标记 The AI Scientist 的 2024、2025 和 2026 年三个关联报告[6,20,21]。同一行的归类用于阅读，不表示互斥分类；图中仅列正文讨论的代表工作。

RAG 以检索结果作为生成条件，把参数化知识与外部资料联系起来[3]。在局部事实查询中，这种结构简洁，回答也便于回到原段落核对。困难出现在信息分散时：一个片段可能包含结论，另一个片段才交代实验条件，单独检索到前者就可能丢失限定。索引与查询之间的匹配关系，因而比片段数量本身更重要。

RAPTOR 把文本片段递归聚类并生成摘要，形成不同抽象层次的索引[22]。高层摘要可以帮助定位跨段落主题，底层片段则保留细节。它改变了可检索的表示，不只是把更多段落放进上下文。但高层摘要也会引入一次新的压缩和解释；若问题涉及具体数值或研究间分歧，仍需沿摘要与原片段的对应关系追索。

GraphRAG 从语料抽取实体和关系，再组织社区及社区摘要[23]。它适合回答面向整个语料的主题性问题，跨文档连接也不必局限在一棵摘要树内。代价是前期抽取、实体消歧和社区构建更复杂，源文本更新后还要维护派生结构。原文主要讨论全局概括的全面性和多样性；这些指标上的改善不能直接解释为每条事实都更准确。图2将三种索引放在相同的“语料—索引—查询”关系中比较。树与图的差别在此十分具体：前者增加抽象层级，后者显式组织交叉关系。对于只需核对一个参数的任务，额外结构未必值得；对于全局主题分析，片段检索又可能不够。

### 3.2 检索中的证据约束

索引之外还有检索决策。Self-RAG 通过专门训练的反思标记判断是否检索，并评价材料相关性、生成支持度和回答质量[24]。它将检索与生成控制联系起来，适合说明“反思”在不同论文中的含义并不一致。这里的反思包含训练目标和控制标记；在普通提示后加上“请检查答案”，并不具备相同机制。

对科研阅读而言，相关性筛选之后还有两道判断。一是材料是否支持所述命题，二是支持的范围是否与写出的结论相符。例如，同一方法在不同数据规模下的结果未必矛盾，若在摘要中删去规模条件，却容易被合并成对方法优劣的泛泛判断。科研 RAG 因此需要保留研究对象、比较条件和来源位置。当文献存在分歧时，检索系统更有价值的输出往往是分歧及其条件，而不是一段措辞顺滑的共同结论。

长上下文扩大了可容纳的材料范围，但模型能否有效利用这些材料仍需检查。Lost in the Middle 在当时的模型和任务中观察到位置敏感性：相关信息位于长输入中部时，利用效果可能下降[25]。这一结论不能替代对新模型的实测，但提示了容量和有效利用是两个变量。在文献规模较小时，直接提供全文可以简化处理；语料较大或来源持续更新时，检索仍承担筛选和定位的作用。将二者结合，比预先认定某一种技术会取代另一种更有实际依据。

### 3.3 长期记忆机制

外部文献描述已有知识，项目记忆则保存本次研究发生过什么。Generative Agents 的记忆流使主体能够选择性地取回经历，并用反思组织后续行为[12]。该研究关注社会行为的可信感，对科研系统的启发主要是历史信息的选择与组织，不能直接据此推断科学判断可靠。

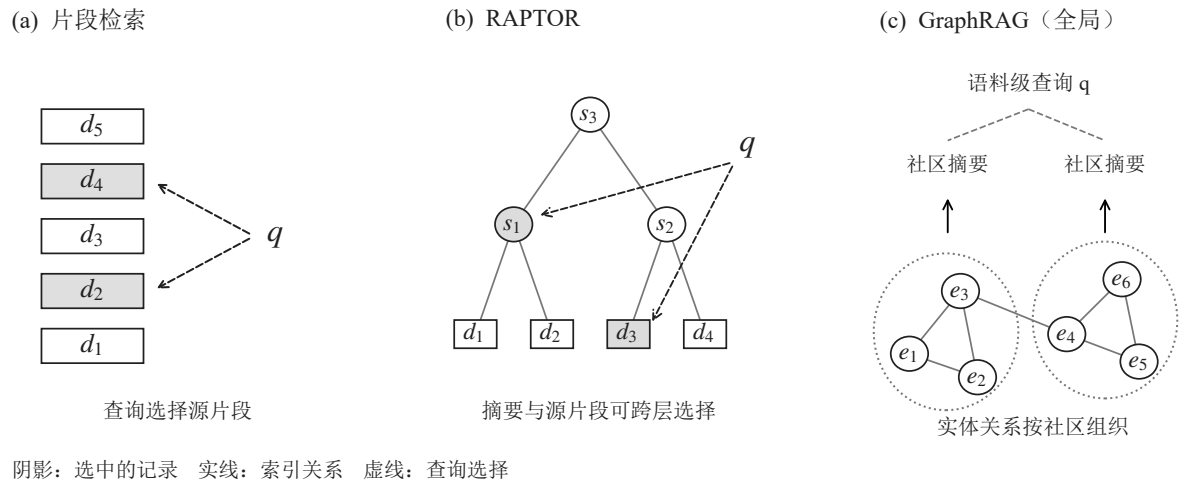



**图 2** 三类检索索引的区别，依据 RAG、RAPTOR 与 GraphRAG 归纳[3,22,23]。$d_i$ 表示源文本片段，$s_i$ 表示摘要，$e_i$ 表示抽取实体；连线分别表示摘要依赖或实体关系。RAPTOR 图中的跨层选择为其检索方式之一；GraphRAG 部分对应全局检索，不表示全部查询都走同一路径。

Reflexion 将一次尝试的反馈写入文字记忆，使模型在不更新权重的情况下调整下一次行动[11]。这与单纯保存对话不同：它选择并解释了失败原因。对于编译错误等反馈明确的问题，解释可以帮助避免重复尝试；若反馈本身含糊，解释也可能把偶然结果写成错误规律。反思因而需要保留其所依据的观察，使后续任务还能检查当时的归因。

MemGPT 处理的重点又有所不同。它用分层存储管理有限上下文，通过显式读写在当前窗口和外部记忆之间调度内容[13]。信息没有遗失，并不保证它被正确理解；存得更久也不会自然提高其可信度。在科研记录中，一次测得的数值、对数值原因的解释和下一步计划应当可区分。若都压缩成“已经解决此问题”，后续代理将很难恢复究竟观察到了什么。

### 3.4 研究记录的来源管理

知识库与任务记忆可以共享文本、向量或图存储，但来源关系仍需保留。一条判断来自论文、来自本次实验，还是来自模型推测，会决定它在后续研究中能承担何种作用。把它们写入同一个无来源区分的库，可能出现这样的循环：模型提出猜测，猜测进入摘要，另一个代理检索到摘要后又将其作为佐证。信息在代理之间传播了多次，独立支持却没有增加。

本文据此更重视判断的可恢复性，而非单纯的记忆容量。对于影响方向选择的结论，应保留产生它的条件和依据；对于反复出现的工具说明，可以压缩或转为外部文档。当新结果否定旧解释时，系统还应知道哪些后续选择受到影响。这种管理比“记住全部对话”更接近科研需求，也把课堂中的知识图谱与自主记忆联系到了同一个实际问题：研究判断如何随新材料而更新。

## 4 多智能体协作机制

### 4.1 角色分工

给多个模型分别设置“教授”“实验员”和“审稿人”，并没有说明它们怎样合作。真正影响结果的是各自看到什么、能够执行什么，以及谁可以要求其他主体返工。AutoGen 用可编程对话组织这类交互[5]；MetaGPT 进一步通过标准化操作流程和中间产物约束交接[14]。前者提供交互的灵活性，后者强调依赖关系和产物规范，二者解决问题的侧重点不同。

科研任务中的角色划分有两种常见依据。按阶段划分，可以由文献代理、实现代理和检查代理顺序处理任务，交付物相对明确；按专业划分，可以让不同领域代理围绕同一问题交换判断，适合尚未确定方法的跨学科讨论。前一种结构容易把上游遗漏传下去，后一种结构则更依赖主持者识别真正的分歧。固定流程、中心调度和自由讨论可以组合使用，单一拓扑往往不足以描述整个系统。

增加通信也有成本。若 $n$ 个主体在每轮都向其余主体发送一次消息，$T$ 轮就有 $Tn(n-1)$ 条有

**表 1** 知识管理方法的机制比较。

| 方法 | 作用机制 | 适用任务 | 主要限制 |
|---|---|---|---|
| **外部知识检索** | | | |
| RAG[3] | 检索原文后条件生成 | 事实查询、来源定位 | 易遗漏分散在多处的条件 |
| RAPTOR[22] | 递归聚类，构建分层摘要 | 长文理解、跨段综合 | 摘要可能压缩关键限定 |
| GraphRAG[23] | 抽取实体关系，生成社区摘要 | 语料级主题分析 | 抽取误差及索引维护成本 |
| Self-RAG[24] | 用反思标记控制检索和生成 | 按需检索、支持度判断 | 需要专门训练和评价设计 |
| **项目经历管理** | | | |
| Reflexion[11] | 把反馈解释写入后续上下文 | 迭代尝试、程序调试 | 错误归因可能固化为经验 |
| MemGPT[13] | 在上下文和外部存储间调度 | 长对话、持续任务 | 容量管理不保证记录可信 |

向消息。这只是理想化计数，实际开销还受消息长度和工具调用影响，但足以说明代理数不是免费的设计变量。对于资料和工具相同的局部任务，重复讨论未必比单个代理增加几次重试更划算。

### 4.2 任务交接

MetaGPT 的启发不只在于模拟软件团队，而在于将中间产物作为下游工作的输入[14]。迁移到科研时，问题就变成：哪些条件必须随任务一起传递。例如，检索者给出一篇支持某方法的论文，还应交代论文中的数据和比较对象；程序编写者提交结果，还应保留产生结果的配置。若交接只留下结论性摘要，检查者很容易再次接受上游的解释，而没有机会核对其依据。

Coscientist 提供了一个具体例子，见图3。Planner 调用文献搜索、装置文档、Python 执行和实验模块，几个模块承担的能力并不相同[19]。其中网络及文档搜索模块使用语言模型，代码执行和自动化模块则执行外部操作。实验模块的接口知识来自装置文档，运行反馈再返回 Planner。这一分工依赖模型规划与不同工具能力之间的衔接，包含语言层面的协调，也包含实际执行。

在此基础上，流程约束还需适应任务中的不确定性。参数核对和代码执行需要明确输入输出，假设探索却可能因新结果改变问题本身。适合固定的是必要条件和记录要求，而不一定是每一步的顺序。系统既要允许改变路径，又要让其他参与者知道为什么改变。

### 4.3 独立核验的条件

ReAct 依靠行动取得新观察，Reflexion 利用反馈调整下一次尝试，多代理辩论则通过交换答案与理由促进修订[4,11,26]。三者都增加了修改机会，却不一定增加同样的信息。一个编译错误定位到程序行为，一次仪器读数来自实验对象；另一段模型批评通常仍在解释已有材料。区分这些反馈，才知道修订究竟纠正了什么。

Huang 等发现，在没有可靠外部反馈的设置中，所测模型的内在自我纠错并不稳定[27]。这与辩论在部分任务中取得收益并不冲突：辩论可能通过候选差异和额外计算改善答案，但不能据此认定形成共识就是完成验证。若多个角色读取同一份有缺陷的摘要，它们即便彼此赞同，也可能始终没有接触被遗漏的条件。

有意义的检查需要适当改变信息或操作。让检查者回到原文核对引述，独立运行分析，或专门寻找与当前假设不符的材料，都比重复评价同一段结论更可能补充判断依据。这并不要求所有代理使用不同基础模型；关键是检查过程能否发现产生者未曾检查的东西。因此，评估检查代理时，应同时看缺陷识别、误报和修改结果，不能只记录它是否给出了批评。

### 4.4 候选方案搜索

研究存在多个候选时，协调者还要决定哪些分支值得继续投入。The AI Scientist-v2 用实验树管理候选实现、调试和改进[21]；AI co-scientist 通过比较、排序和演化更新假设集合[18]。前者主要在实现空间搜索，后者更多在假设空间搜索，两者依赖的反馈也不同。

搜索会同时改变结果质量和结果的解释。多次尝试后报告最优分支，可以展示系统在给定预算下找到好方案的能力，却不代表一次尝试的平均表现。如果分支始终依据测试成绩筛选，还可能把评价集变成搜索的一部分。因而，自动科研

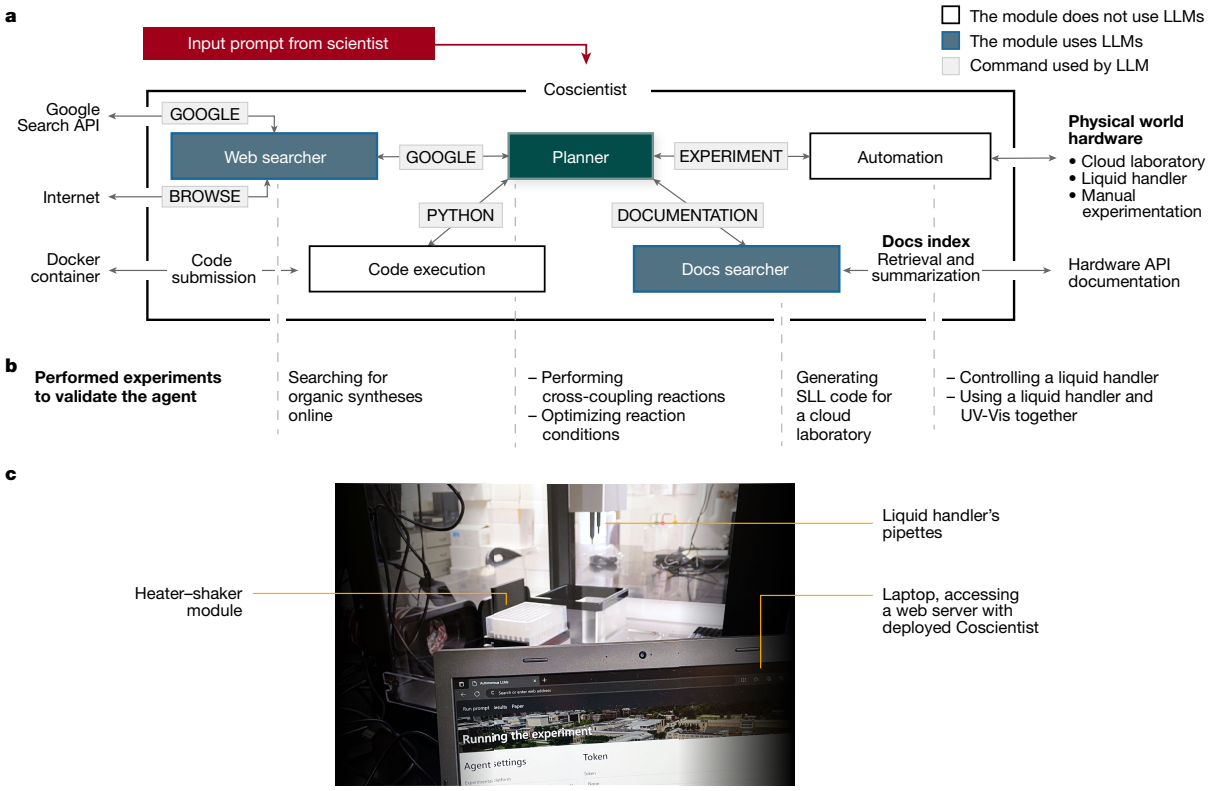



**图 3** Coscientist 的实际系统架构、模块验证任务与实验装置。转载 Boiko 等[19]原图 1，保留原文标注：蓝色模块使用 LLM，白色模块不使用 LLM，绿色为 Planner。原图依据CC BY 4.0转载，未改动内部内容。

报告应保留尝试预算、筛选依据和失败分支；对于评审模型给出的候选排名，则仍需安排相应的外部检验。

## 5 科研应用

### 5.1 文献驱动的研究构思

文献系统的任务并不总是生成一段回答。PaperQA2 把检索、证据整理与带引用的综合联系起来，并以文献问答和矛盾识别考察系统[28]。与给定段落上的阅读理解相比，这类系统还要决定继续找什么材料，以及已有材料是否足以作答。它的研究价值首先体现在资料覆盖和来源利用，而不是替代实验发现。

ResearchAgent 进一步从核心论文出发，结合学术关系与概念知识生成问题、方法和实验构想，再由评审代理提出修改意见[15]。SciAgents 则利用本体知识图谱组织跨概念探索，强调多主体讨论与材料研究构思[16]。前者以论文及相关工作组织候选，后者更突出图中的概念连接。二者都把已有知识用于提出尚待研究的问题，但与 PaperQA2 相比，产出已从可查证的文献综合转向开放候选，评价也随之变难。

这种难度不是加一个新颖性评分就能消除的。候选与既有研究不同，不代表它可以实施；机制描述自洽，也不代表相应效应存在。人工和模型评审适合筛除明显重复或缺乏可行性的构思，其后的实验设计仍需回答：什么结果会支持这一想法，什么结果会使它被放弃。因此，判断此类系统时，应把候选形成和候选验证分开记录。否则，研究建议得到高分就容易被误读为发现本身取得成功。

### 5.2 端到端计算科研

计算研究能把数据、程序和指标接入同一执行环境，是端到端科研较早采用的路径。The AI Scientist 早期系统从预设代码模板出发，生成创意、修改代码、运行实验并撰写论文[20]。模板缩小了可探索空间，也减少了环境与基础实现的不确定性。因而，早期结果较直接地反映了系统在已有研究起点上的延伸能力。

第二版引入实验树搜索，减少对人工代码模板的依赖，把实现、调试和改进组织为分支探索[21]。2026 年期刊稿同时研究聚焦和开放模式，并报告实际工作坊评审案例[6]。这条研究线的变化在于逐渐扩大系统能够选择的空间，而非简单增加写作能力。工作坊评审为内部自动评分增加了外部参照，但特定主题和接受条件下的个案仍不足以代表广泛的自主科研能力。三份关联报告各有用途：

早期稿解释初始设计，第二版说明搜索机制，期刊稿提供进一步的实验与评审证据。

Agent Laboratory 选择了另一种目标：接受人给定的研究想法，并允许研究者在文献、实验及报告阶段介入[17]。它与追求完全自主的系统并不处在同一条单轴排名上。若研究者已明确问题，快速形成可修改的实现和初步结果可能比自动选择题目更有帮助。但人工参与也必须计入评价。原文特定设置下，自动总体评分为 6.1/10，人工评分为 3.8/10，提示了评审模型与人的判断可能明显不同。仅用生成论文的流畅程度或模型偏好评价协作式科研工具，会遗漏实验设计和研究者修改负担。

### 5.3 生物医学假设验证

AI co-scientist 在专家给定目标下组织生成、反思、排序与演化，通过多次候选比较提出研究建议[18]。它与计算实验系统的区别，在于许多分支还没有可即时执行的科学检验。排序者可以判断哪种建议更值得继续考察，却无法仅凭比较给出命题为真的概率。其药物再利用、肝纤维化靶点和细菌基因转移机制等案例，需要分别阅读相应验证：细胞或类器官实验提供特定体系中的支持，与未公开机制相符合则说明另一种推断能力。把这些结果都压缩成“发现成功率”，反而会丢失最有价值的信息。

Virtual Lab 将跨学科代理会议落实为纳米抗体设计流程[7]。人类提出高层目标，负责人及专业代理讨论方法，并结合蛋白质语言模型、结构预测与 Rosetta 等专门工具选择候选。这里的能力至少来自三个部分：语言模型组织研究，专用模型评价候选，实验检验实际表现。它们在流程中相互配合，不能把最终结果全部归于代理对话。

论文对 92 个候选进行实验表征；其中 78 个具有更高的相应结构置信度，60 个具有更优的 Rosetta 结合能，但不同亲本系列的实际结合表现并不一致[7]。这一差别尤其值得保留。计算筛选指标决定哪些候选值得测量，实验功能才回答相应生物学问题。较高预测分数可以支持筛选，却不能替代表达、结合等具体测量。对于这类系统，最有解释力的材料应同时包括候选怎样产生、怎样筛选，以及实际测到了什么。

### 5.4 化学实验自动化

ChemCrow 将 18 种专业工具接入语言模型，用于化学检索、计算、合成规划和实验任务[29]。Co-scientist 进一步把装置文档、代码执行和实验设备连在一起[19]。与第 4 节的架构相对应，后者不仅能提出实验步骤，还需要生成装置可接受的命令，并根据返回结果调整操作。专业工具在此提供了通用语言模型本身不具备的计算与执行能力。

图4保留 Coscientist 原文两种偶联反应的实验面板。上方总离子流色谱给出产物相关峰的保留时间，中、下方将该时间点的质谱与标准物质对照。以 Suzuki 反应为例，原文在 9.53 min 处取谱，并展示联苯标准；Sonogashira 反应对应 12.92 min 处取谱及二苯乙炔标准。这里对产物的判断具有可核对的测量对象，与语言模型声称“反应已经成功”有本质区别。原谱图的意义也正在于保留了这种核对关系，而不只是作为系统完成任务的配图。

不过，仪器读数也没有解除实验设置本身的限制。可选试剂、设备能力和部分人工操作规定了 Coscientist 的活动范围[19]。该研究说明语言模型可以在给定装置中衔接若干实验环节，开放实验室中的持续自主研究仍有更复杂的资源与异常处理问题。表2据此按产出和验证方式比较代表系统，避免将文献能力、计算能力和实体实验混成一种成绩。

## 6 实证评价

### 6.1 评价对象

科研系统可以交付答案、程序、实验方案或一篇论文，评价不能只依据同一个文本分数。文献回答需要检查来源支持，程序任务需要核对执行结果，开放研究还涉及选题、对照和解释。表3列出几种常用评价工作的对象；它们回答不同问题，并没有形成一个统一的科研能力量尺。

ScienceAgentBench 从 44 篇同行评审论文中提取 102 项数据驱动任务，要求系统生成独立程序并保存输出[30]。有效执行率（valid execution rate，VER）检查能否执行并产生规定输出；任务成功率（success rate，SR）进一步检查是否达到各项任务的标准。这一差别使实验中一个常被忽略的事实可见：程序已经运行，任务仍可能没有完成。基准针对的是研究工作流中的具体计算任务，而非一项完整发现。

RE-Bench 采用 7 个开放机器学习研究工程环境，并引入人类专家尝试[31]。其人与代理的相对表现随时间预算改变：代理在短预算下表现较强，而人类在更长预算下取得更明显的后续收益。这

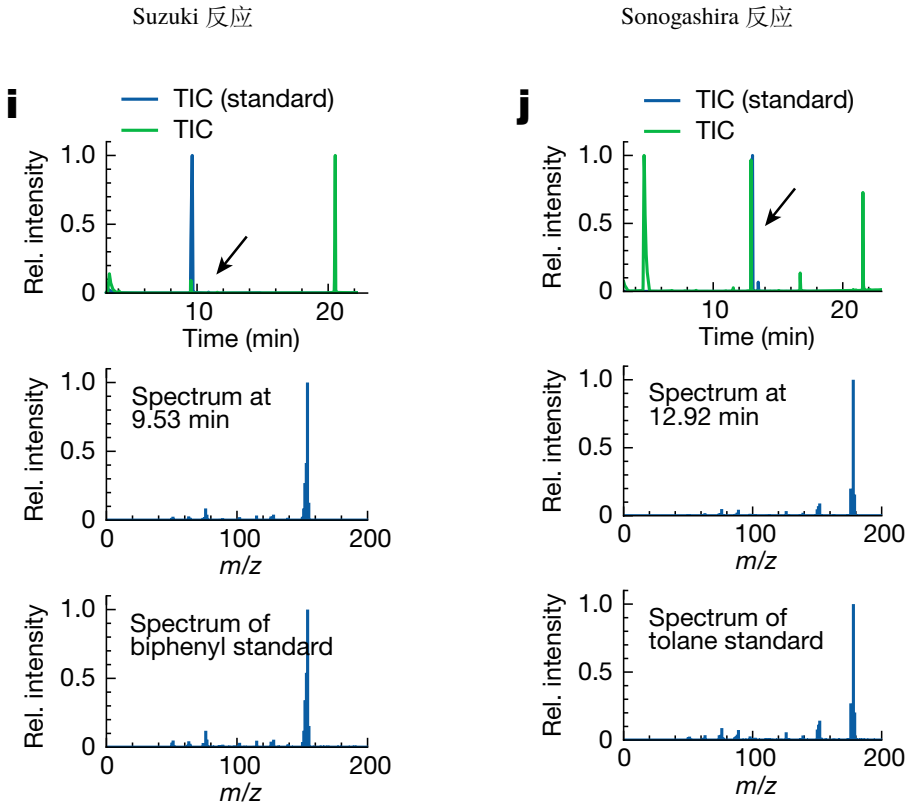



**图 4** Coscientist 偶联反应的色谱与质谱验证。上部为总离子流色谱（TIC），中部为指定保留时间的质谱，下部为对应标准物质。转载 Boiko 等[19]原图 5i、5j，依据CC BY 4.0，保留原曲线、坐标和数值，仅提取面板并并列排版。

**表 2** 代表性科研系统的产出及验证方式。

| 系统 | 研究产出 | 原报告采用的验证方式 |
|---|---|---|
| **文献综合与研究构思** | | |
| PaperQA2[28] | 带引用的文献综合 | 文献问答、矛盾识别及专家比较 |
| ResearchAgent[15] | 问题、方法与实验构思 | 迭代评审及案例分析 |
| SciAgents[16] | 跨概念的材料研究构思 | 代理评议及材料研究案例 |
| **计算研究** | | |
| The AI Scientist[6,20,21] | 程序实验与研究论文 | 程序实验、自动评审及工作坊评审 |
| Agent Laboratory[17] | 人给定目标下的计算研究 | 人工评分、模型评分及后端比较 |
| **生物医学与化学实验** | | |
| AI co-scientist[18] | 迭代排序后的研究假设 | 专家反馈，部分候选接受生物医学检验 |
| Virtual Lab[7] | 纳米抗体设计候选 | 计算筛选及纳米抗体实验表征 |
| ChemCrow[29] | 化学检索、计算和合成规划 | 专家评估及部分实验任务 |
| Coscientist[19] | 实验程序及产物测量 | 装置反馈、色谱与质谱对照 |

注：验证均限于原报告设定的任务条件。The AI Scientist 一行归并同一研究系列的不同报告。

一结果提醒研究者，“超过专家”必须与任务、时间和尝试分配一起报告。代理快速搜索若干方案与专家长期改进同一研究，并不是可以不计资源直接比较的活动。

### 6.2 执行反馈的实证表现

图5重绘 ScienceAgentBench 中两个模型在三种框架下的结果。直接生成（Direct）提供简单参照，Self-Debug 允许依据执行反馈修订，OpenHands CodeAct 提供更广的交互动作。原协议对

**表 3** 科研评价工作的任务及测量内容。

| 评价工作 | 任务材料 | 主要测量内容 |
|---|---|---|
| PaperQA2 / LitQA2[28] | 检索、综合与矛盾识别 | 回答质量、来源支持及专家比较 |
| ScienceAgentBench[30] | 44 篇论文中的 102 项任务 | VER、SR、代码相似度及费用 |
| RE-Bench[31] | 7 个研究工程环境 | 不同时间预算下的任务收益 |
| MAST[32] | 多代理轨迹及失败案例 | 规范、协调和核验环节的失败类型 |
| 科研过程审计[8] | 100 个受控审计案例 | 方法学缺陷识别准确率 |

注：VER 为有效执行率，SR 为任务成功率。各工作的任务、预算及评分定义不同，成绩不可直接合并。

每项任务独立运行三次，依次按 SR、VER、CodeBERTScore 和较低费用择优，再汇总入选运行。这些数值因此反映择优后的表现，不是一次运行的均值。

在无专家知识的设置中，Claude 3.5 Sonnet 与 Self-Debug 结合的 VER 为 92.2%，SR 却为 32.4%；GPT-4o 对应为 83.3% 与 22.6%[30]。两者分别相差 59.8 和 60.7 个百分点。仅有汇总数据还不能把差距归因到某一种错误，却足以否定“程序能运行就完成了任务”的判断。执行反馈能排除一部分实现问题，数据处理和科学目标仍需要单独检查。

资源投入也没有与成功率形成简单的单调关系。Claude 3.5 Sonnet 使用 OpenHands 时，平均 API 费用为 0.958 美元、SR 为 21.6%；Self-Debug 对应为 0.057 美元和 32.4%[30]。这里比较的是相同模型、相同基准下的框架配置，说明更大的动作空间不一定更容易被有效利用。它支持将简单反馈方案列为基线，尚不能推广成某一框架在所有任务中更优。同样，这组实验比较的是代理框架，并未直接分离多代理角色协作的效果。

### 6.3 科研过程审计

MAST 将多代理失败整理为规范与系统设计、主体间失配以及任务核验等类别[32]。这类过程分类有助于定位问题：目标理解错误、交接丢失条件和过早结束任务，可能需要完全不同的修正。只看最终论文，往往无法区分这些原因。

Luo 等进一步考察自动科研中的基准选择偏差、数据泄漏、指标误用、事后选择和数据替换或编造等缺陷[8]。在其 100 个正负均衡案例上，审计模型仅阅读论文时总体准确率为 55%，同时获得日志和代码后提高到 82%。图6以各类识别正确的案例数展示这一变化。数据泄漏从 11/20 提高到 18/20，事后选择从 10/20 提高到 14/20，说明过程材料的帮助在不同问题上也有差异。

这一实验支持提供过程材料，却没有测量真实科研中缺陷有多常见。案例数量、受控注入和正负比例规定了结果的解释范围；图中也不据此补出总体发生率或不确定区间。更值得注意的是，论文与过程记录能够回答的问题不同。前者陈述最终采用的分析，后者可能揭示筛掉了哪些尝试、何时查看过测试结果、训练和测试数据究竟如何使用。自动化越深入，这种差别越有可能影响对研究的判断。

### 6.4 协作增益的归因分析

若要识别协作贡献，单代理基线应具有相应的检索、执行和重试机会，并尽量匹配模型、工具、预算与人工帮助。否则，多代理系统获得的提升虽是系统层面的真实差异，却未必来自角色分工。消融还需要说明资源如何重新分配：删除检查者并同时减少调用次数，不能单独回答检查角色是否必要。

更有针对性的比较是保留总预算后合并角色，或保留角色数量但改变检查者能访问的材料。前者观察分工与通信是否值得，后者观察检查的信息来源是否产生增益。对长期任务，还可检查系统在一项关键判断被推翻后，能否找出受影响的后续实验。这些评价比单独增加一个最终答案分数更难，但也更贴近科研协作实际要解决的问题。

## 7 讨论

### 7.1 研究判断的可追溯性

前述方法中，检索扩大了可使用的资料，记忆延续了项目经历，协作则把不同操作连接起来。它们的共同困难，是在转换过程中保留判断的依据。一段原文变成摘要，一次运行变成实验结论，再变成下一个代理的任务输入，每次转换都可能丢掉条件。因此，本文认为科研系统应优先保存

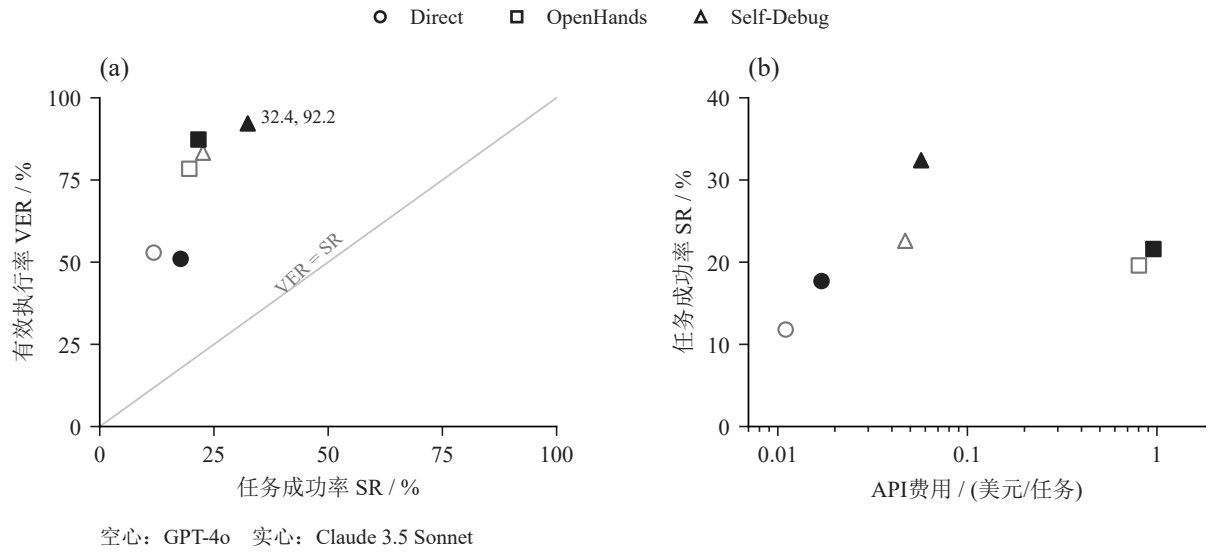



**图 5** ScienceAgentBench 中六组配置的执行、成功与费用。数据取自文献[30]表 3（v3，PDF 第 8 页），均不提供专家知识，共 102 项任务，每项三次独立运行后择优。(a) VER 与 SR；(b) SR 与平均 API 调用费用，对数横轴。模型和美元费用对应原报告时期；点表示表 3 汇总结果，不是三次运行均值。

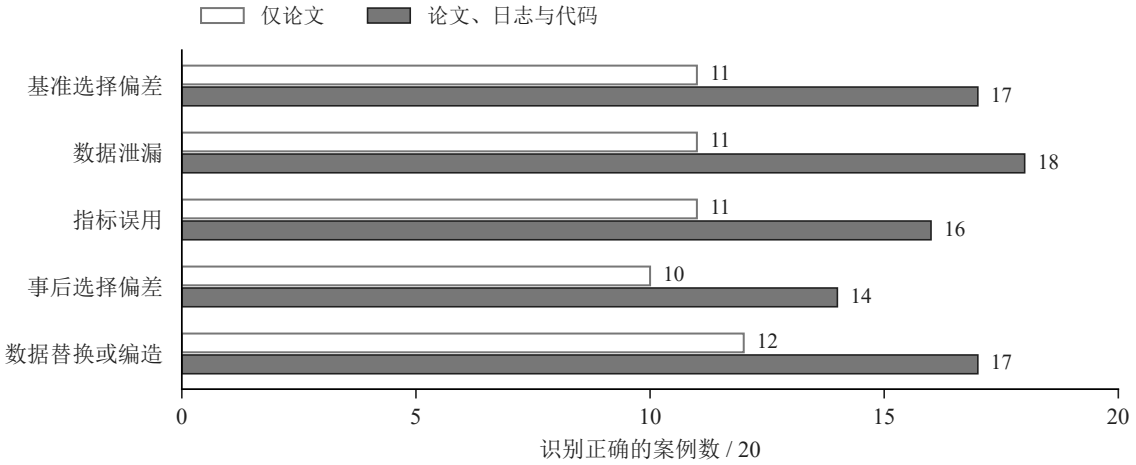



**图 6** 补充过程材料后的缺陷识别。由文献[8]第 6.2 节及表 11（v2，PDF 第 16–18 页）中的准确率换算为正确案例数；每类 20 例，阳性、阴性各 10 例，部分缺陷为原作者受控注入。审计模型为 gemini-2.5-flash-preview-05-20；日志与代码同时加入，未分别估计二者贡献。

可恢复的研究判断，而非只保存尽可能多的文本。

这里的“判断”不必采用复杂的新表示。一个实验结果至少应能关联数据、配置和比较对象；一个解释应能关联它试图说明的观察。若后续发现数据处理有误，系统应沿这些联系找到需要重做的分析。这与课堂中的图式知识组织相通，但图的价值在于表达可检查的依赖，而不在于把所有文本都变成节点。尚未检验的解释也不宜直接写成稳定事实。

相应地，自主记忆不应只考察模型记住了多少旧内容。更有区分力的问题是：新的证据出现后，系统能否指出哪些旧认识需要修改。这要求它区分原始观察与自己的解释，也要求保留修订历史。目前以长对话或单次任务完成率为主的评价，对这一点覆盖仍然有限。它是知识图谱和项目记忆可以互相补充的方向，也是二者尚未自然结合的地方。

### 7.2 探索与验证的预算分配

在自动构思成本下降之后，研究瓶颈可能转向验证。AI co-scientist 式的候选演化可以扩大探索范围，Virtual Lab 式的专用模型筛选可以减少部分实验负担，但最终仍需要与问题相匹配的观察。对于验证昂贵的任务，继续增加候选可能只会把负担转移给实验者。因此，搜索预算不宜只

**表 4** 科研协作机制的建议对照设计。

| 研究因素 | 固定条件 | 比较设置 | 主要观察量 |
|---|---|---|---|
| 记忆来源标记 | 存储容量、检索预算 | 有无来源标记；<br>是否区分观察与解释 | 错误重复、反证利用；<br>关键判断的恢复 |
| 角色分工 | 基础模型、工具权限；<br>总调用预算 | 合并或拆分角色 | 完成质量、通信与返工成本 |
| 独立核验 | 角色数、调用预算 | 改变核验材料的可访问性 | 缺陷识别、误报及修正结果 |
| 人工介入 | 任务目标、评价标准 | 改变介入阶段及修改程度 | 研究质量、专家时间与修改量 |

注：所列为本文建议的研究设计，尚未在本综述中开展相应实验。

按生成数量分配，还应考虑哪些候选可以被现有数据或一次有区分力的实验排除。

这并不意味着所有新想法都要先符合现有共识。探索恰恰需要保留尚未证实的解释。合理的检查应指出事实基础、逻辑跳跃和可检验条件，允许候选在不确定状态下继续存在。模型评审如果只偏好熟悉且容易论述的方案，可能压缩真正需要探索的空间。如何同时保留探索性与严格验证，是科研代理比一般问答更难评价的原因之一。

代理数与研究质量之间同样缺少普遍的单调关系。当角色提供不同资料、专业工具或独立重算时，分工有清楚的理由；当所有角色共享一份摘要并重复赞同，通信的增加未必增加证据。本文因此倾向于按任务安排分工，并通过对照决定哪些角色值得保留。这比预设一个规模越来越大的虚拟团队更容易解释，也更便于控制费用。

### 7.3 科研流程中的人工参与

Agent Laboratory 和 Virtual Lab 表明，人工参与可以是研究方法的一部分，而非系统自主性的缺陷[7,17]。研究者选择问题、判断对照是否合适、解释异常结果，这些活动未必适合由固定验收规则替代。相反，资料定位、常规执行和初稿整理较容易交给工具。把人的时间用于最能改变研究方向的节点，可能比追求每一步无人参与更有实际价值。

但协作式系统不能只报告最终结果，同时省略人在背后的工作。人工提供了多少初始方案、修改了多少代码、重新解释了哪些结果，都会影响对系统贡献的判断。未来实验应把这些投入与质量变化一起记录。表4列出由上述分析得到的几项具体对照；它们是本文建议的研究问题，不是已经得到验证的解决方案。

### 7.4 本综述的局限

本文选取的工作主要用于解释知识、记忆、协作和评价之间的关系，并非穷尽检索。不同报告使用的模型、任务、工具与人工参与差异较大，不能据其公开分数计算一个领域总体效应。同一项目多个版本也不构成独立重复验证。数值图保留原报告条件，未重新执行所引系统；早期模型和费用主要用于分析机制与评价问题，不代表当前产品性能。

此外，长期科研中的方向调整和失败积累仍缺少统一的评价方式。本文提出保存判断依赖和检查信息增量，尚未证明它们在不同学科中都具有相同收益。要进一步检验这些判断，需要保留跨阶段轨迹，并在条件允许时让独立执行者复查。综述所能完成的是说明为什么值得这样检查，而不是替尚未开展的实验给出结论。

## 8 结论

科研多智能体已将文献检索、状态管理、工具执行与研究交流组织到同一流程。片段检索、层次摘要和关系图支持不同尺度的资料访问，反思与分层存储处理历史信息，协作协议组织任务交接。文献综合、计算研究和实体实验的案例展示了这些方法的用途，也暴露出执行成功与科学验证之间的差距。

本文的主要判断是：协作的价值取决于它是否带来更充分的资料、更有区分力的检查和更可恢复的研究过程。角色数量、论文生成速度或自动评审分数，单独都不足以回答这一问题。下一步需要在相同资源条件下比较具体机制，并把研究依据、失败尝试和人的投入纳入评价。

## 参考文献


[1] Zheng T, Deng Z, Tsang H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C]//Proceedings of EMNLP. 2025: 17733–17750. DOI:10.18653/v1/2025.emnlp-main.895.

[2] Wei J, Yang Y, Zhang X, et al. From AI for Science to Agentic Science: A Survey on Autonomous Scientific Discovery[EB/OL]. 2025. arXiv:2508.14111v2.

[3] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. 2020. arXiv:2005.11401v4.

[4] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//International Conference on Learning Representations. 2023. arXiv:2210.03629v3.

[5] Wu Q, Bansal G, Zhang J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation[EB/OL]. 2023. arXiv:2308.08155v2.

[6] Lu C, Lu C, Lange R T, et al. Towards end-to-end automation of AI research[J]. Nature, 2026, 651: 914–919. DOI:10.1038/s41586-026-10265-5.

[7] Swanson K, Wu W, Bulaong N L, et al. The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies[J]. Nature, 2025, 646: 716–723. DOI:10.1038/s41586-025-09442-9.

[8] Luo Z, Kasirzadeh A, Shah N B. The More You Automate, the Less You See: Hidden Pitfalls of AI Scientist Systems[EB/OL]. 2025. arXiv:2509.08713v2.

[9] 郑逸宁, 余镇, 李不凡, 等. 大语言模型的工具使用综述 [J]. 自动化学报, 2025, 51(11): 2371–2386. DOI:10.16383/j.aas.c240793.

[10] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: Language Models Can Teach Themselves to Use Tools[EB/OL]. 2023. arXiv:2302.04761v1.

[11] Shinn N, Cassano F, Berman E, et al. Reflexion: Language Agents with Verbal Reinforcement Learning[EB/OL]. 2023. arXiv:2303.11366v4.

[12] Park J S, O'Brien J C, Cai C J, et al. Generative Agents: Interactive Simulacra of Human Behavior[EB/OL]. 2023. arXiv:2304.03442v2.

[13] Packer C, Wooders S, Lin K, et al. MemGPT: Towards LLMs as Operating Systems[EB/OL]. 2023. arXiv:2310.08560v2.

[14] Hong S, Zhuge M, Chen J, et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework[C]//International Conference on Learning Representations. 2024. arXiv:2308.00352v7.

[15] Baek J, Jauhar S K, Cucerzan S, et al. ResearchAgent: Iterative Research Idea Generation over Scientific Literature with Large Language Models[C]//Proceedings of NAACL: Human Language Technologies. 2025: 6709–6738. DOI:10.18653/v1/2025.naacl-long.342.

[16] Ghafarollahi A, Buehler M J. SciAgents: Automating scientific discovery through multi-agent intelligent graph reasoning[EB/OL]. 2024. arXiv:2409.05556v1.

[17] Schmidgall S, Su Y, Wang Z, et al. Agent Laboratory: Using LLM Agents as Research Assistants[EB/OL]. 2025. arXiv:2501.04227v2.

[18] Gottweis J, Weng W H, Daryin A, et al. Towards an AI co-scientist[EB/OL]. 2025. arXiv:2502.18864v1.

[19] Boiko D A, MacKnight R, Kline B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624: 570–578. DOI:10.1038/s41586-023-06792-0.

[20] Lu C, Lu C, Lange R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. 2024. arXiv:2408.06292v3.

[21] Yamada Y, Lange R T, Lu C, et al. The AI Scientist-v2: Workshop-Level Automated Scientific Discovery via Agentic Tree Search[EB/OL]. 2025. arXiv:2504.08066v1.

[22] Sarthi P, Abdullah S, Tuli A, et al. RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval[C]//International Conference on Learning Representations. 2024. arXiv:2401.18059v1.

[23] Edge D, Trinh H, Cheng N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization[EB/OL]. 2024. arXiv:2404.16130v2.

[24] Asai A, Wu Z, Wang Y, et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[EB/OL]. 2023. arXiv:2310.11511v1.

[25] Liu N F, Lin K, Hewitt J, et al. Lost in the Middle: How Language Models Use Long Contexts[EB/OL]. 2023. arXiv:2307.03172v3.

[26] Du Y, Li S, Torralba A, et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate[EB/OL]. 2023. arXiv:2305.14325v1.

[27] Huang J, Chen X, Mishra S, et al. Large Language Models Cannot Self-Correct Reasoning Yet[EB/OL]. 2023. arXiv:2310.01798v2.

[28] Skarlinski M D, Cox S, Laurent J M, et al. Language agents achieve superhuman synthesis of scientific knowledge[EB/OL]. 2024. arXiv:2409.13740v2.

[29] Bran A M, Cox S, Schilter O, et al. Augmenting large language models with chemistry tools[J]. Nature Machine Intelligence, 2024, 6: 525–535. DOI:10.1038/s42256-024-00832-8.

[30] Chen Z, Chen S, Ning Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C]//International Conference on Learning Representations. 2025. arXiv:2410.05080v3.

[31] Wijk H, Lin T, Becker J, et al. RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts[EB/OL]. 2024. arXiv:2411.15114v2.

[32] Cemri M, Pan M Z, Yang S, et al. Why Do Multi-Agent LLM Systems Fail?[EB/OL]. 2025. arXiv:2503.13657v2.